



Processus d'annotation sémantique

pour favoriser l'interopérabilité autour des données de

biodiversité au sein de l'infrastructure AnaEE-France

A. Chanzy, E. Aivayan, N. Beudez, C. Callou, P. Clastre, M. El-Hamadry,
L. Greiveldinger, B. Jaillet, F. Lafolie, A. Léturgie, A. Maire, C. Martin, D.
Maurice, N. Moitrier, G. Monet, H. Raynal, A. Schellenberger, R. Yahiaoui

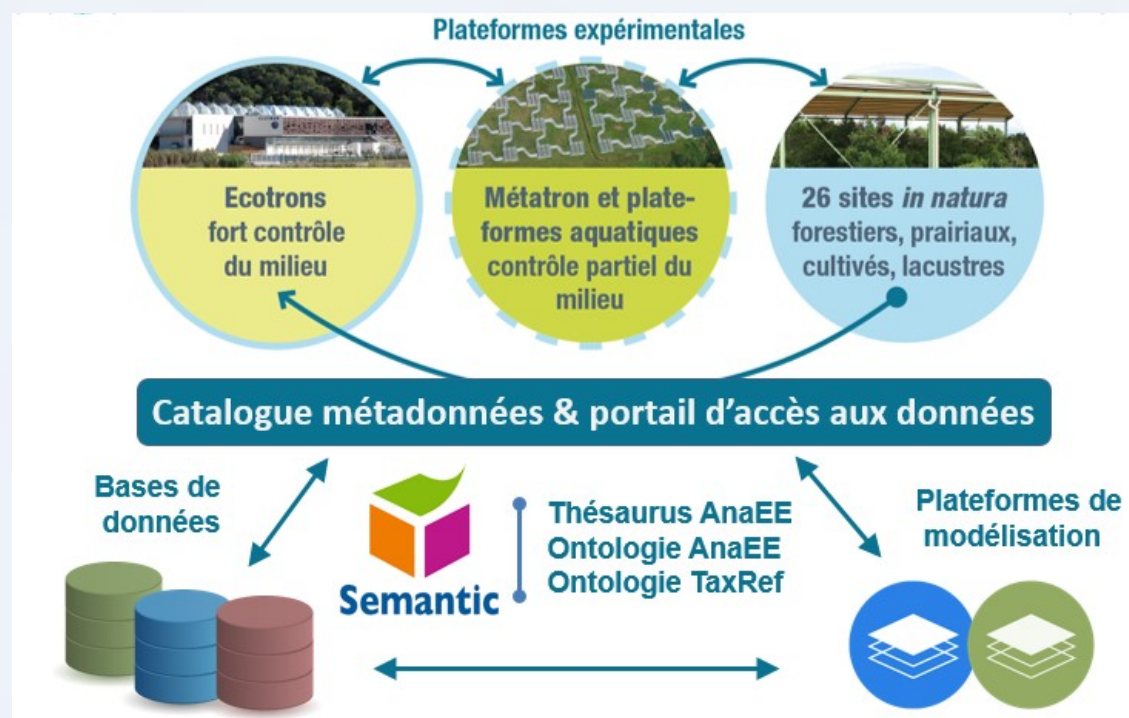


*R. Yahiaoui
P. Christian
D. Maurice
A. Schellenberger*



Intro

- Infrastructure nationale "Analyse et Expérimentation sur les Écosystèmes"
- Offre à la communauté scientifique des plateformes d'expérimentation, de modélisation et des BDD (dont celles des SOERE)

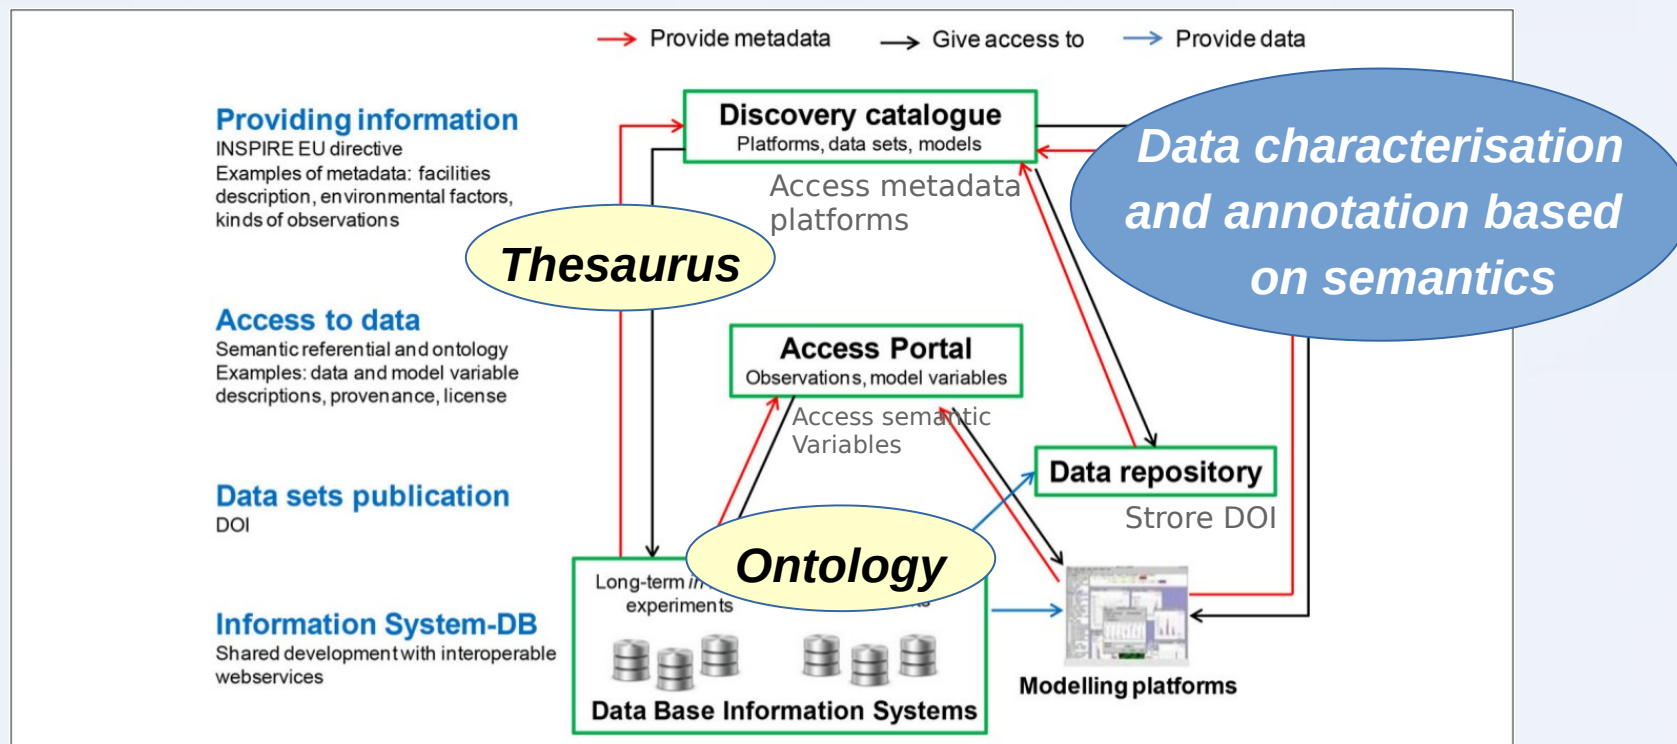


Hétérogénéité ⇒ Interopérable



Intro

AnaEE, Un Système d'Information distribué ...



Diverses DB

Concepts différents / Mêmes concepts décrits de différentes façons

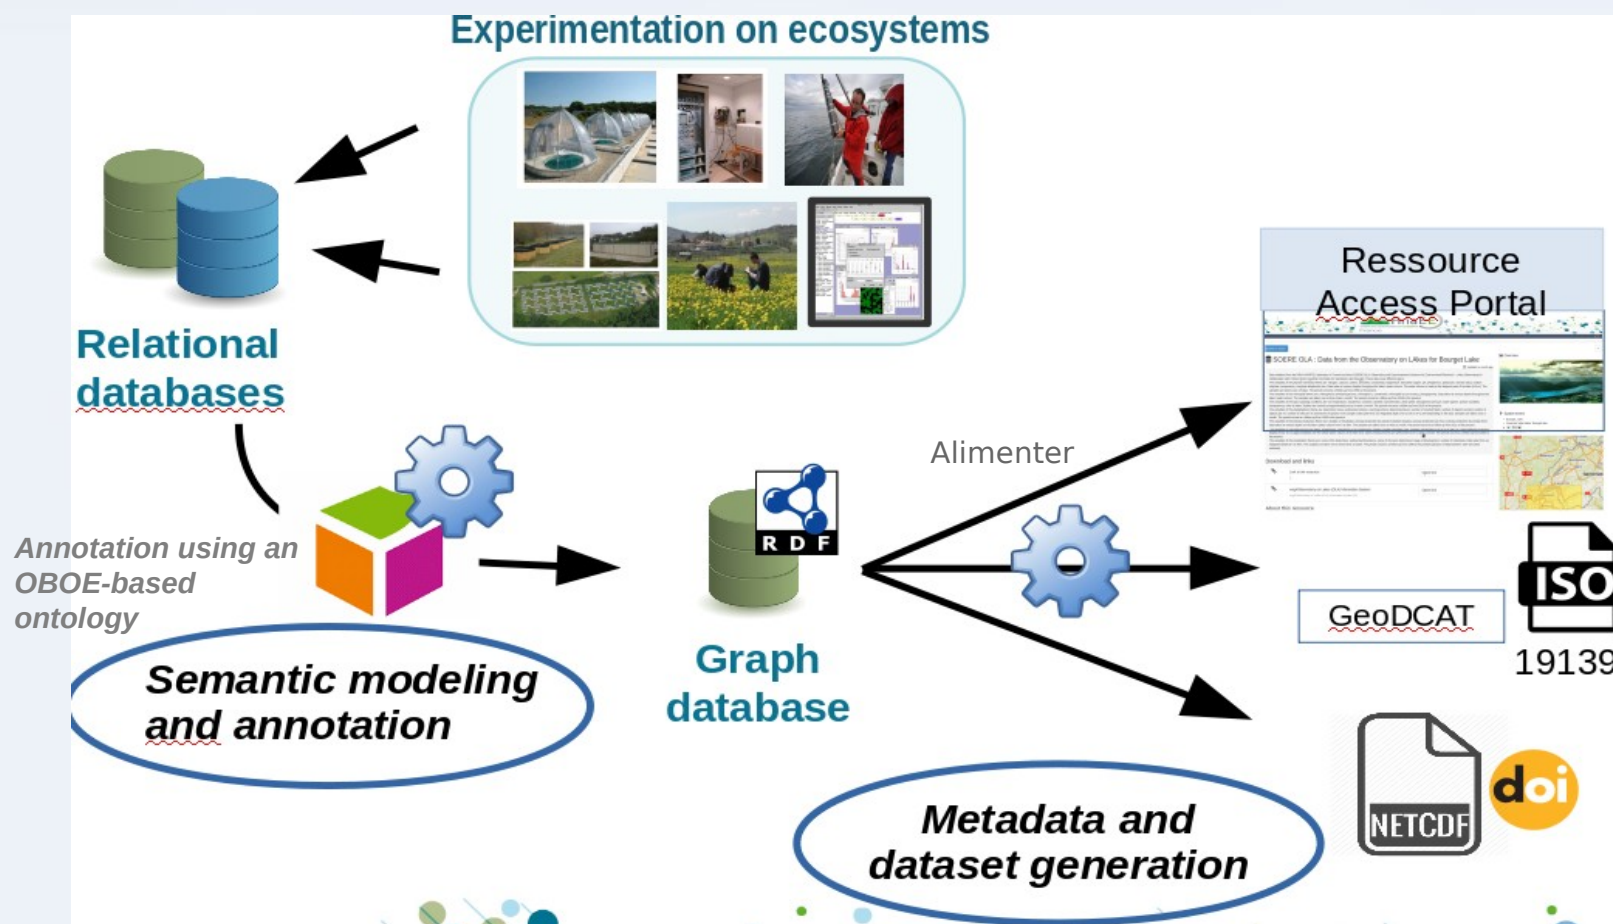
⇒ Pour aligner ces concepts (les homogénéiser) et donc les rendre interoperable..

⇒ Approche choisie : **web Sémantique**




Intro

Un flux de gestion des données/métadonnées





Et c'est justement ce qui fera l'objet de cette présentation...

Processus d'annotation et production de données sémantiques



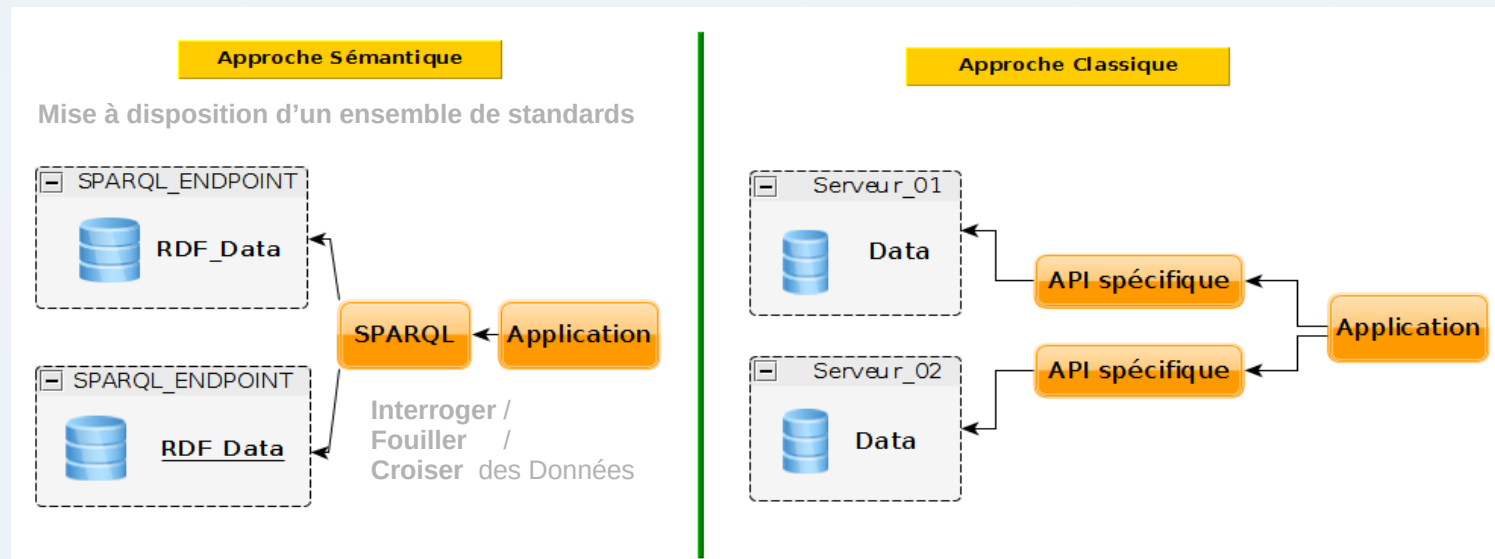
Définitions
Démarche suivie



Aspects Fonctionnels 
Algorithme / Code 

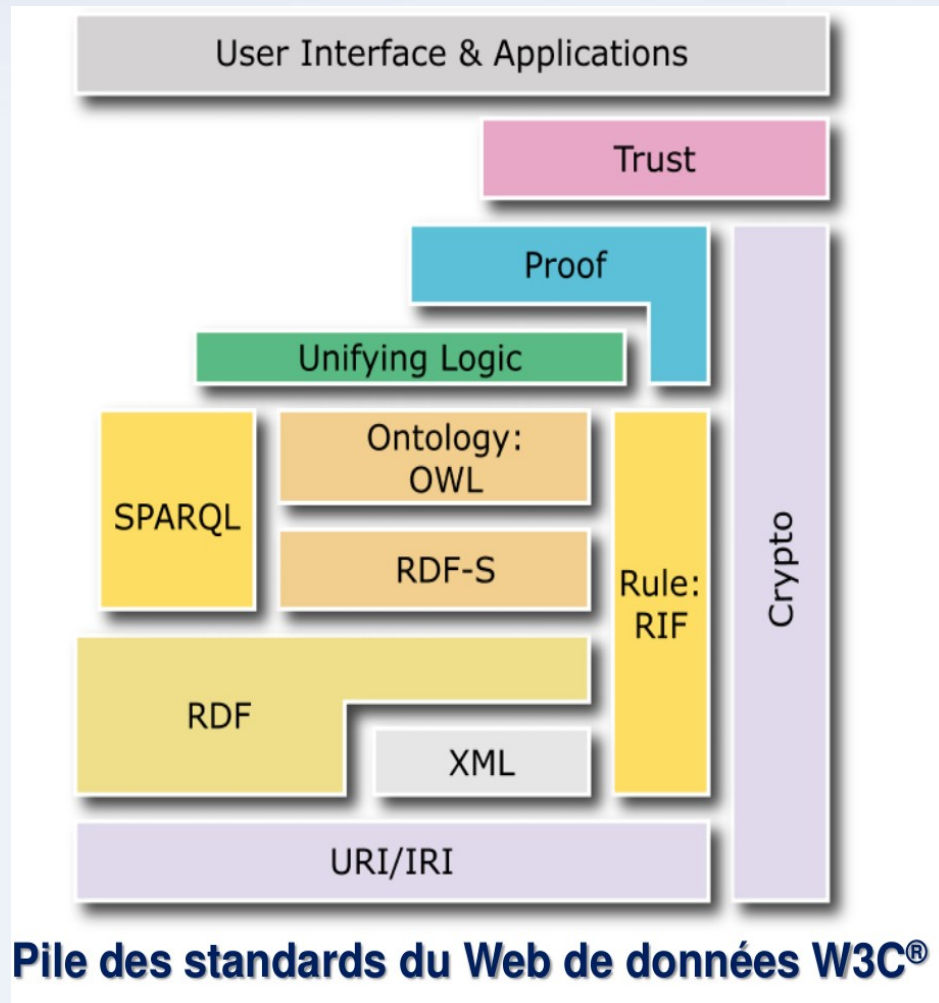


Le **Web sémantique**, ou toile sémantique, est un mouvement collaboratif mené par le World Wide Web Consortium (W3C) qui [favorise des méthodes communes pour échanger des données sur Internet pour accéder simplement..](#) (Wikipedia)





Pile de Standardisation



URI - IRI : Identifier n'importe quel objet du monde sur le web

RDF Moyen pour représenter les ressources et de leur associer des descriptions (structurées)

SPARQL Interroger / Fouiller / Croiser des Données

RDFS Vocabulaire pour décrire des ontologies légères

OWL Vocabulaire pour décrire des ontologies plus poussées

Un père est un homme qui a au moins un enfant
(MINACARDINALITY ...)

Traçabilité et **vérification** des données afin de les valider.

Interaction : Faciliter l'interaction des utilisateurs avec les données

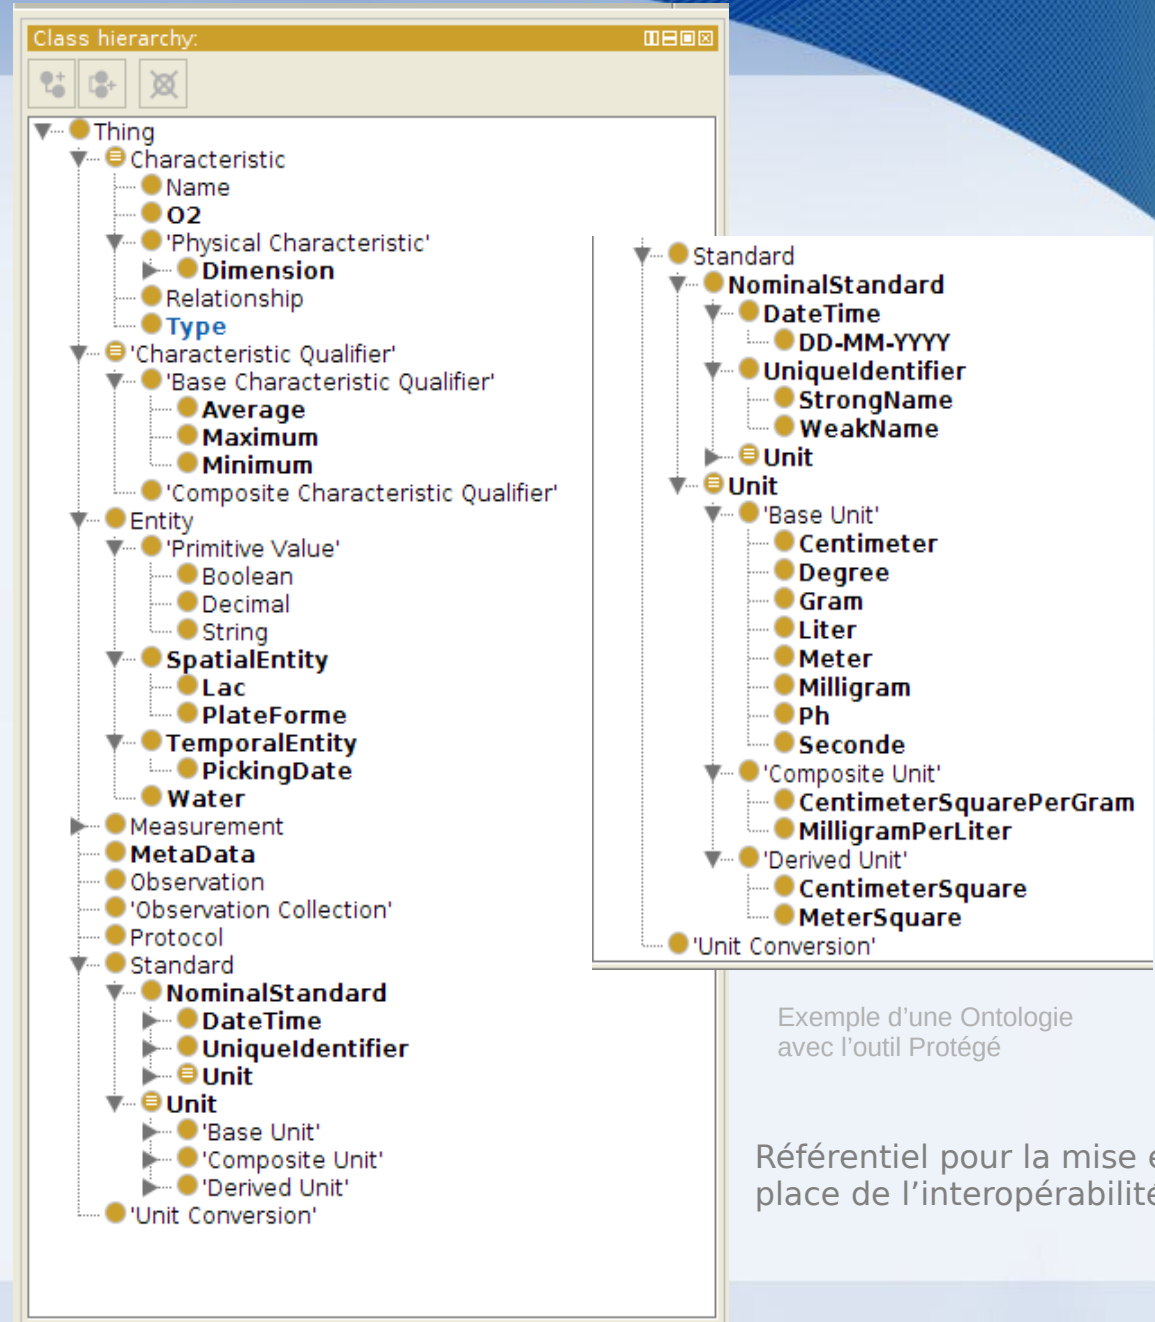
Ontologie

Une Ontologie est un **réseau sémantique** regroupant un ensemble de **concepts décrivant un domaine**. Ces concepts sont **liés les aux autres** par des relations hiérarchiques d'une part, et sémantiques d'autres part.

Restriction, cardinalité des propriétés, symétrie, transitivité, inversement fonctionnel, intersection, union, disjonctions....

Mais aussi Thésaurus

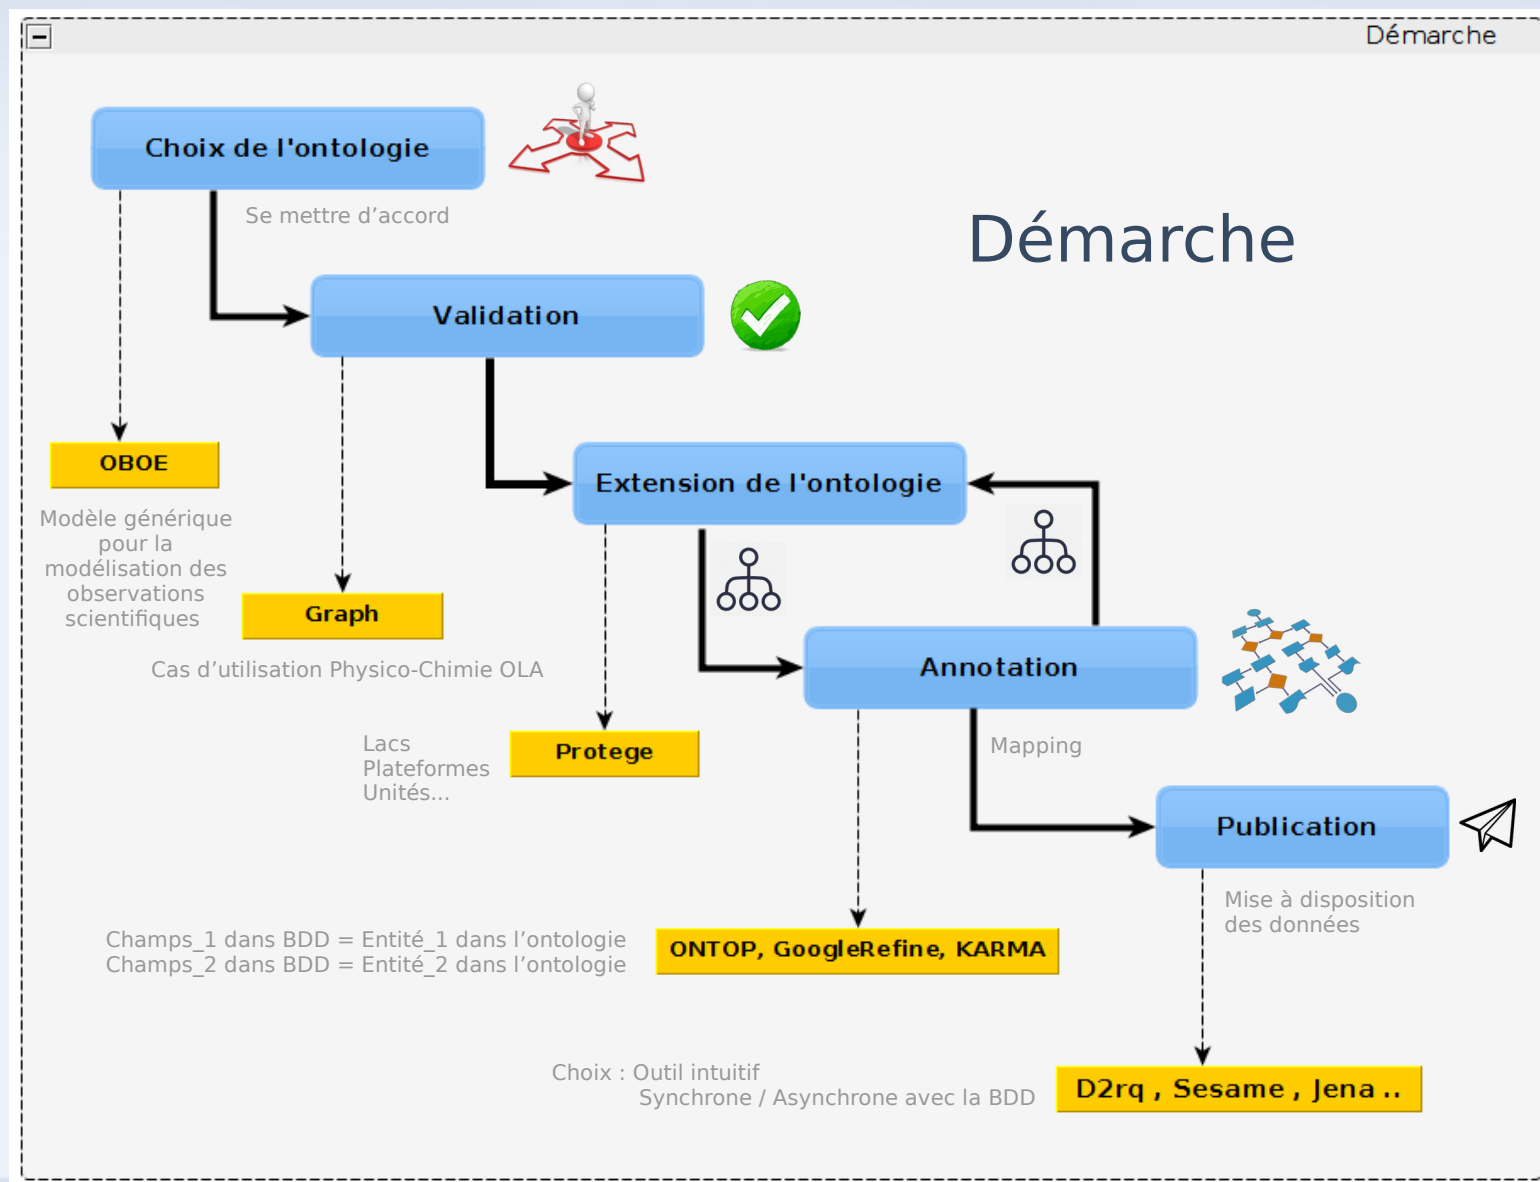
Liste structurée et hiérarchisée des termes d'un domaine du savoir plus ou moins large. Chacun des mots est relié à d'autres par divers types de relations hiérarchiques et/ou associatives



Exemple d'une Ontologie avec l'outil Protégé

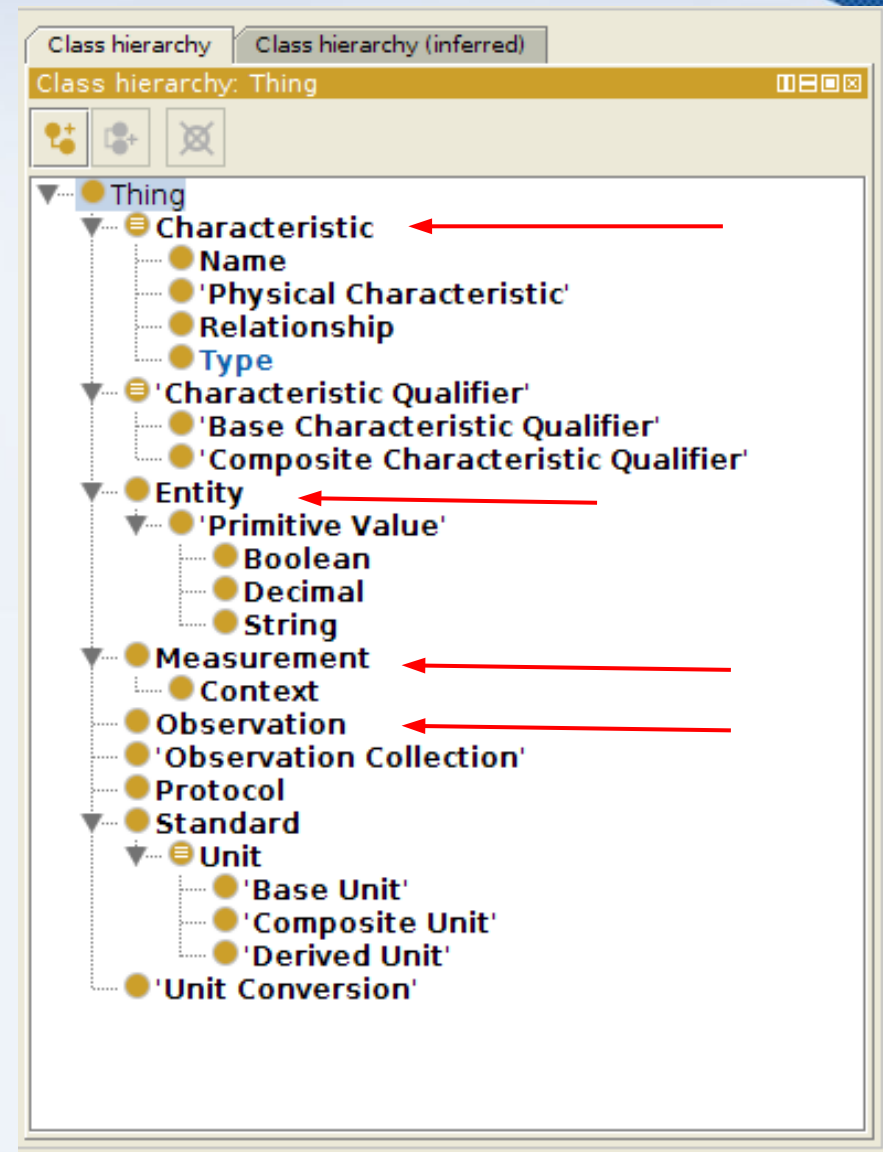
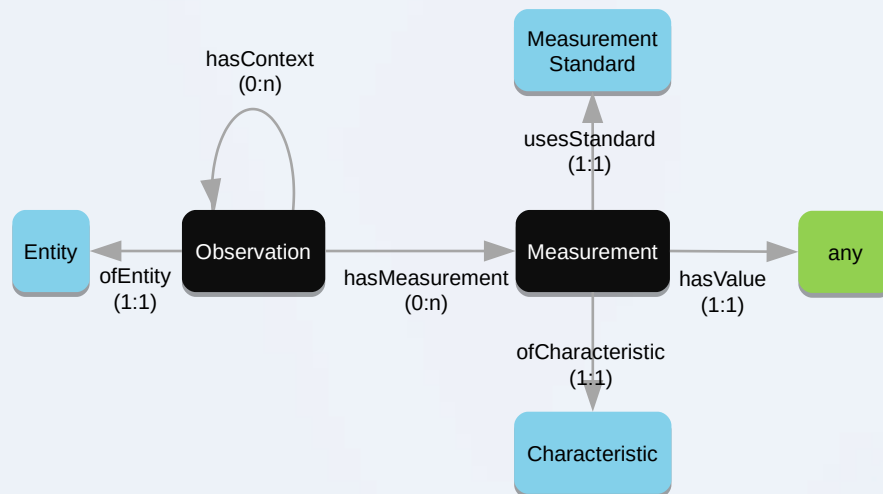
Référentiel pour la mise en place de l'interopérabilité

Mise en place de l'interopérabilité - AnaEE-F



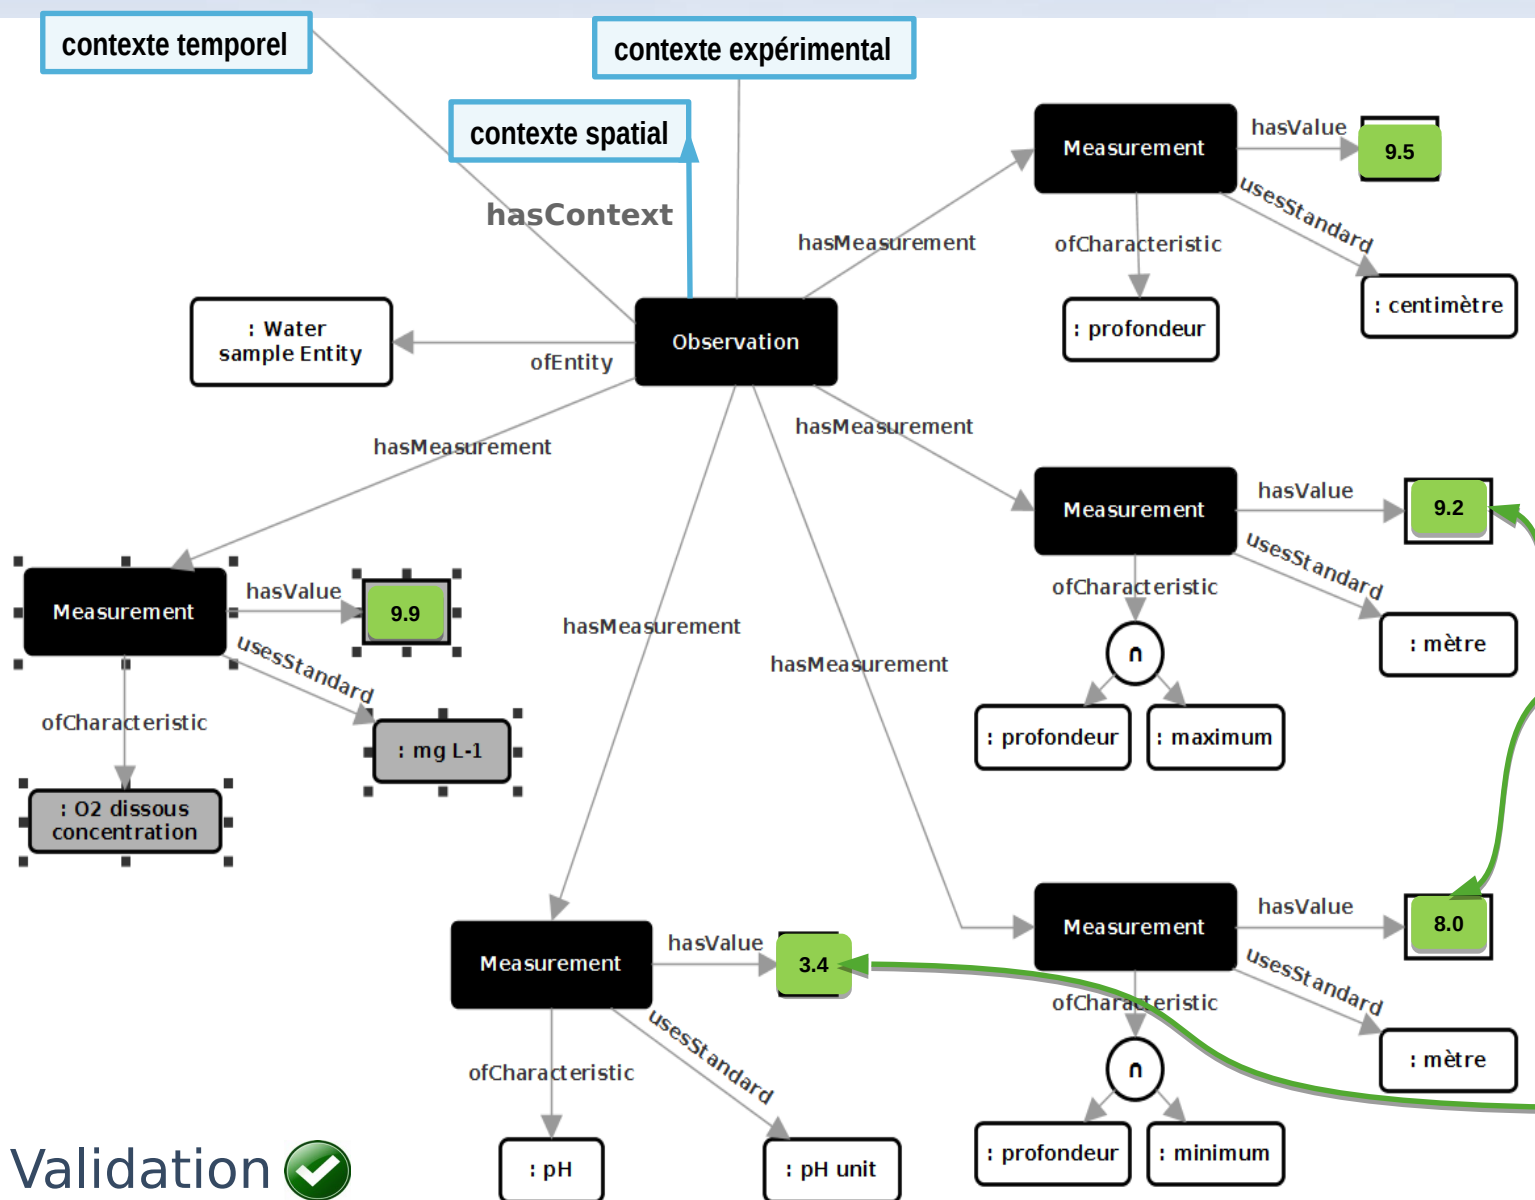
OBOE

Ontologie conçue comme étant un modèle générique pour la modélisation et la représentation des observations scientifiques



Validation

Modélisation sous forme de graphe. Cas d'utilisation : **Physico-Chimie**



mesure_chimie_mchimie	
<input type="checkbox"/>	mchimie_id
<input checked="" type="checkbox"/>	profondeurmax
<input checked="" type="checkbox"/>	profondeurmin
<input checked="" type="checkbox"/>	profondeurreelle
<input type="checkbox"/>	sschimie_id

valeur_mesure_chimie_vmchimie	
<input type="checkbox"/>	vmchimie_id
<input type="checkbox"/>	flag
<input type="checkbox"/>	ligne_fichier_echange
<input checked="" type="checkbox"/>	valeur
<input type="checkbox"/>	mchimie_id
<input type="checkbox"/>	var_id

Validation

Extension OBOE

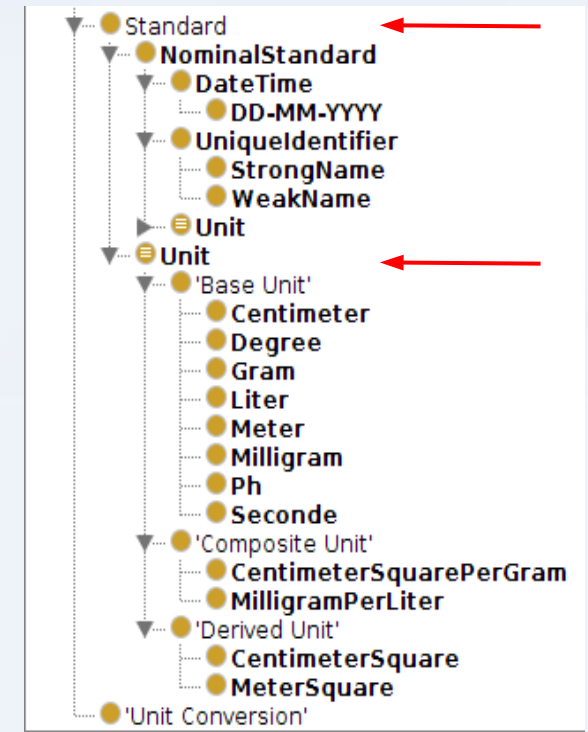
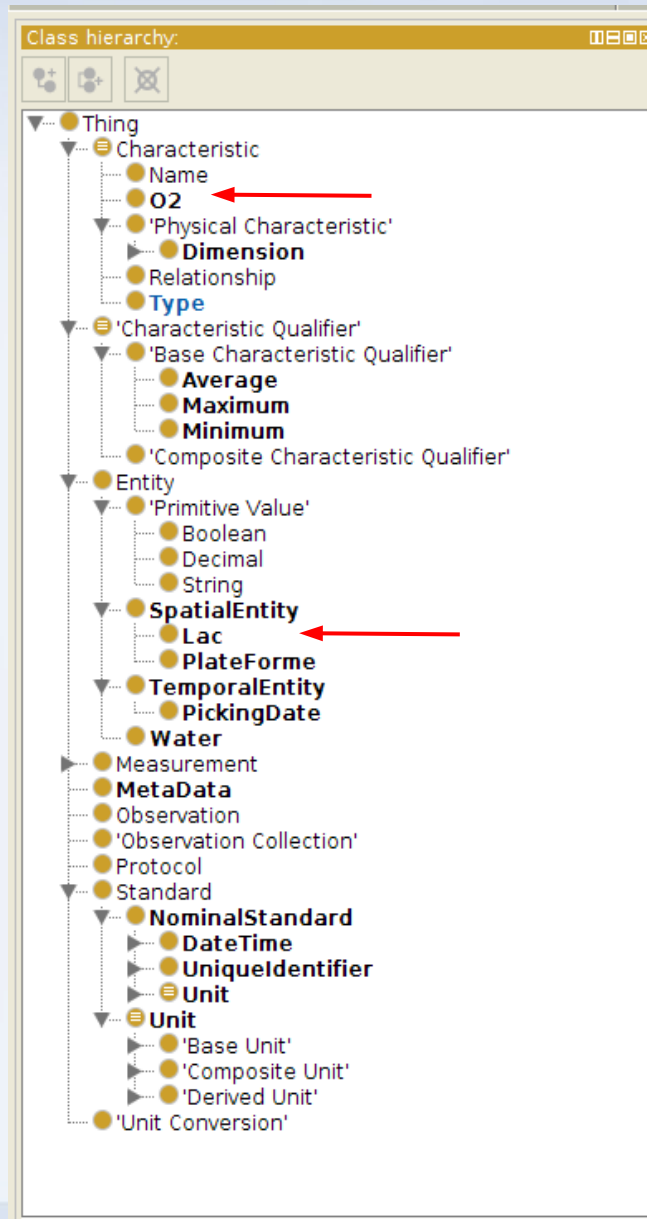
OBOE-CORE

+

'Thésaurus'

=

Ontologie AnaEE-F



Data		
Nom	employeur	HomePage
MichelGagnon	poly	http://www.professeurs.polymtl.ca/michel.gagnon

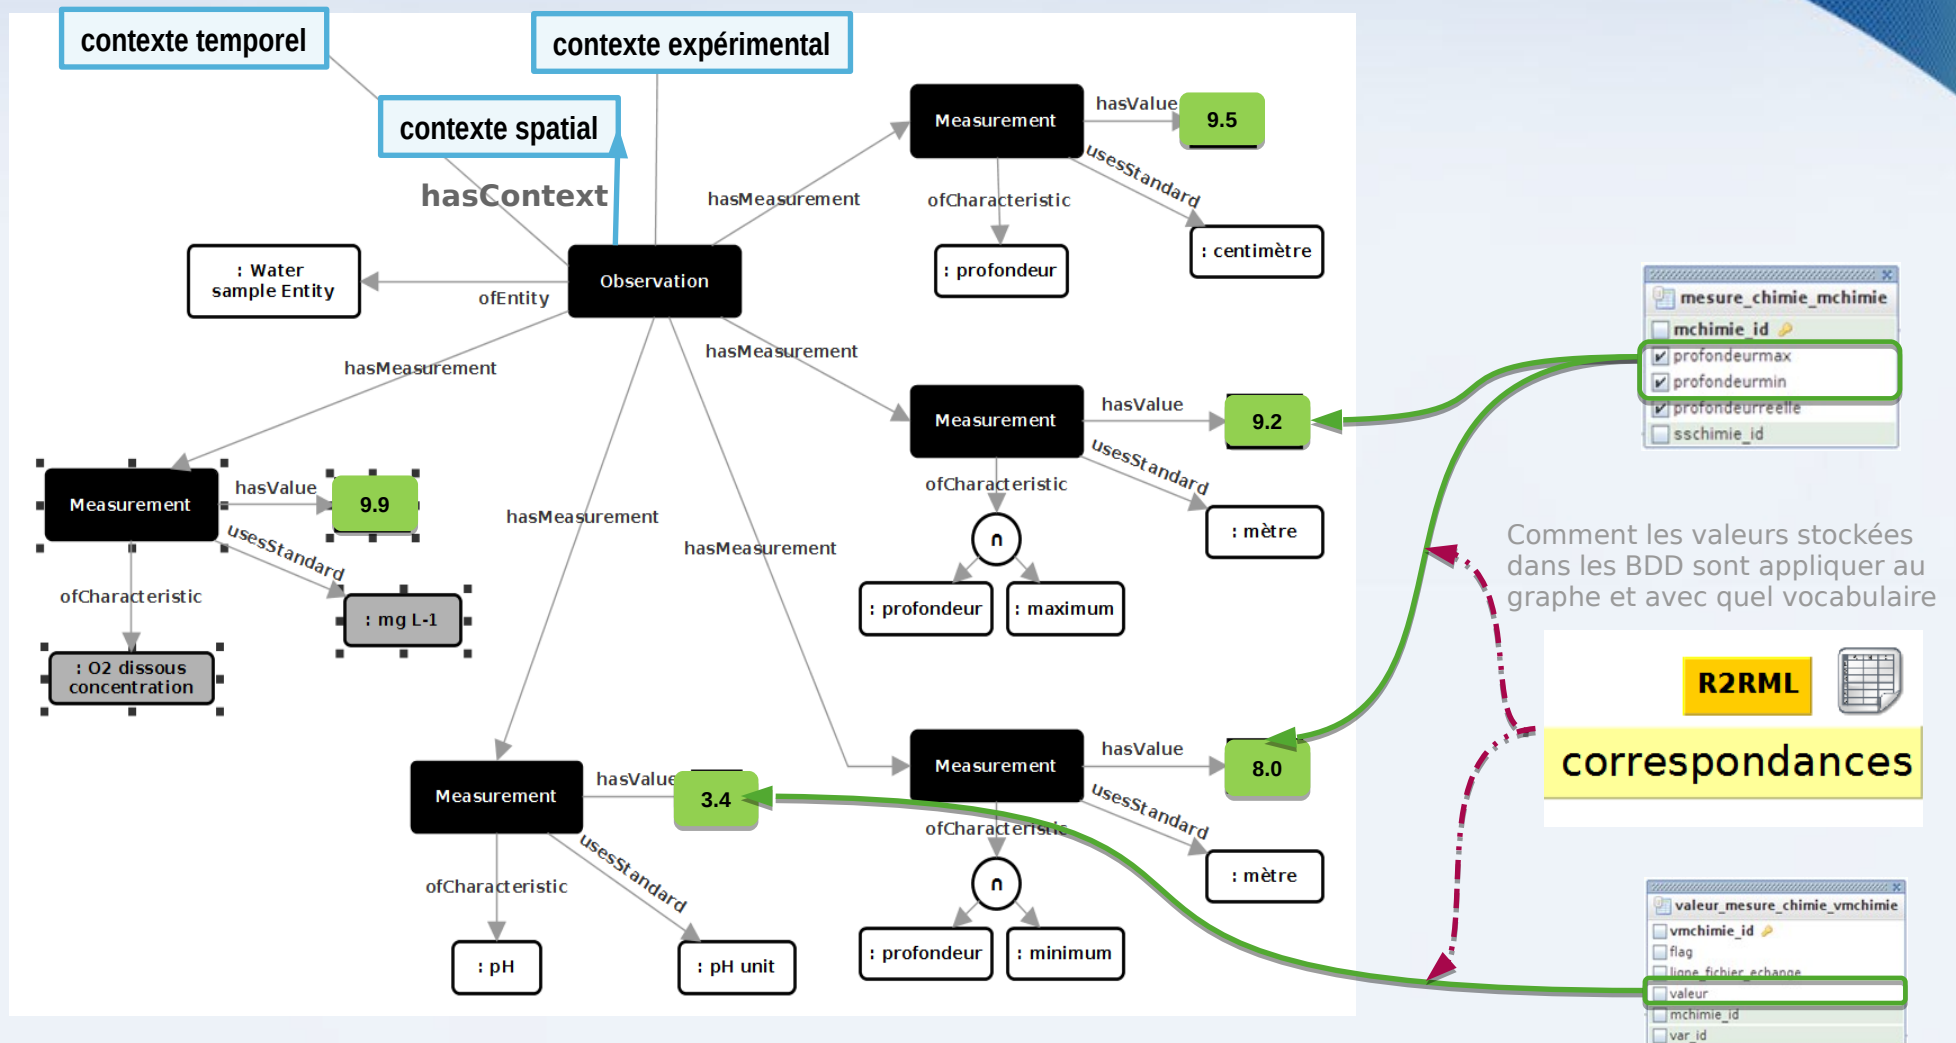


N-Triples

```
#s1 :Nom "MichelGagnon"
#s1 :Employeur "poly"
#s1 :HomePage "http://www.professeurs.polymtl.ca/michel.gagnon"
```

Le Sujet représente la ressource ,
 Le Prédicat représente une propriété applicable sur la ressource
 L'objet représente une données ou une autre ressource

Annotation [Transformation RDB - RDF (2/2)]



Maintenant qu'on sait ce qui doit être fait.. il ne reste plus qu'à trouver les bons outils...

Inventaire des outils sémantiques (Sparql Endpoint)

(Phase de Publication Des Données)



TripleStore

* Sesame



- Robustesse : **K.O**
- Scaling out : **K.O**
- Performance : **ERR**


* Sol-RDF



- Robustesse : **OK**
- Scaling out : **OK**
- Performance :

REST

* BlazeGraph



- Robustesse : **OK**
- Scaling out : **OK ***
- Performance : **OK**

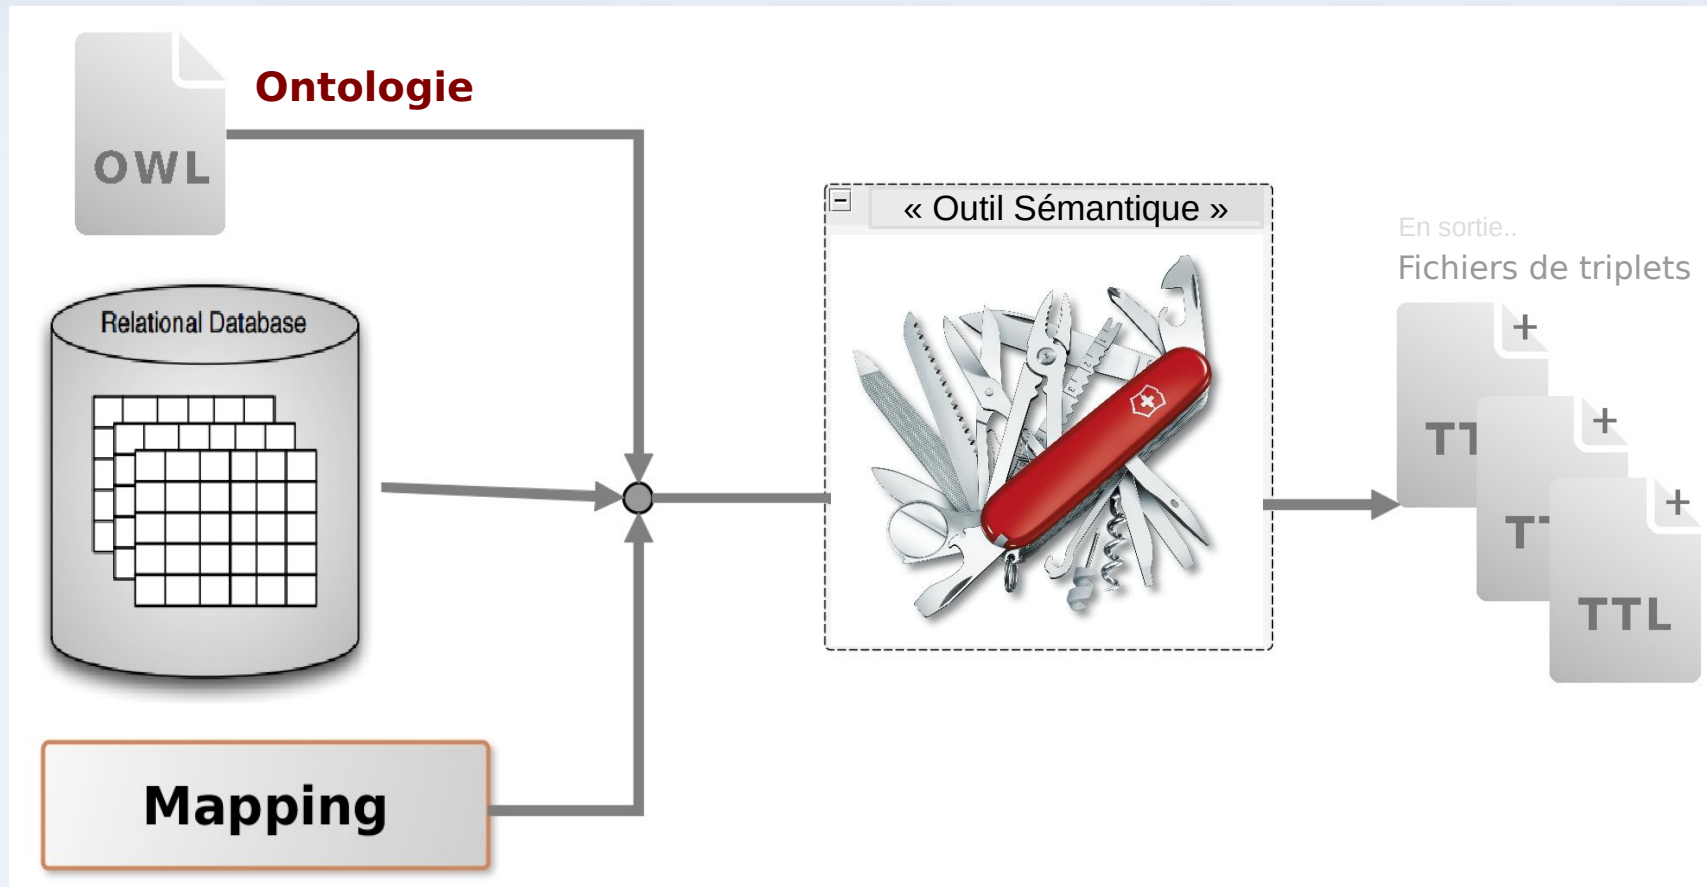
* Corese



- Robustesse : **OK**
- Scaling out :
- Performance : **OK**

Bases de données orientées Graphes (Structure plus généralisée que celles des triplestores)

Inventaire des outils sémantiques (Phase d'annotation)



Comment les données
relationnelles sont transformées
en données sémantique...

Inventaire des outils sémantiques (Phase d'annotation)



Outils de transformation à la volée



```
d2rq:column      "Conferences.Name"
d2rq:condition   "PAPER.PDF IS NOT NULL"
d2rq:join        "Papers.Conference => Conferences.ConfID"
```



```
SELECT ID, VALUE FROM measurements
```

- Transformation à la volée des requêtes

SPARQL ⇒ SQL (Génération RDF à partir des BD-R)



- Mapping non Intuitif (Spécialement pour ceux qui ne manipulent que du SQL)

- ~~Fail Last~~ Erreurs Mapping détectées au Runtime- ~~Pas d'Interface graphique !~~ Projet Externe (AuReli)

- On-the-fly Ontology-based Data Access



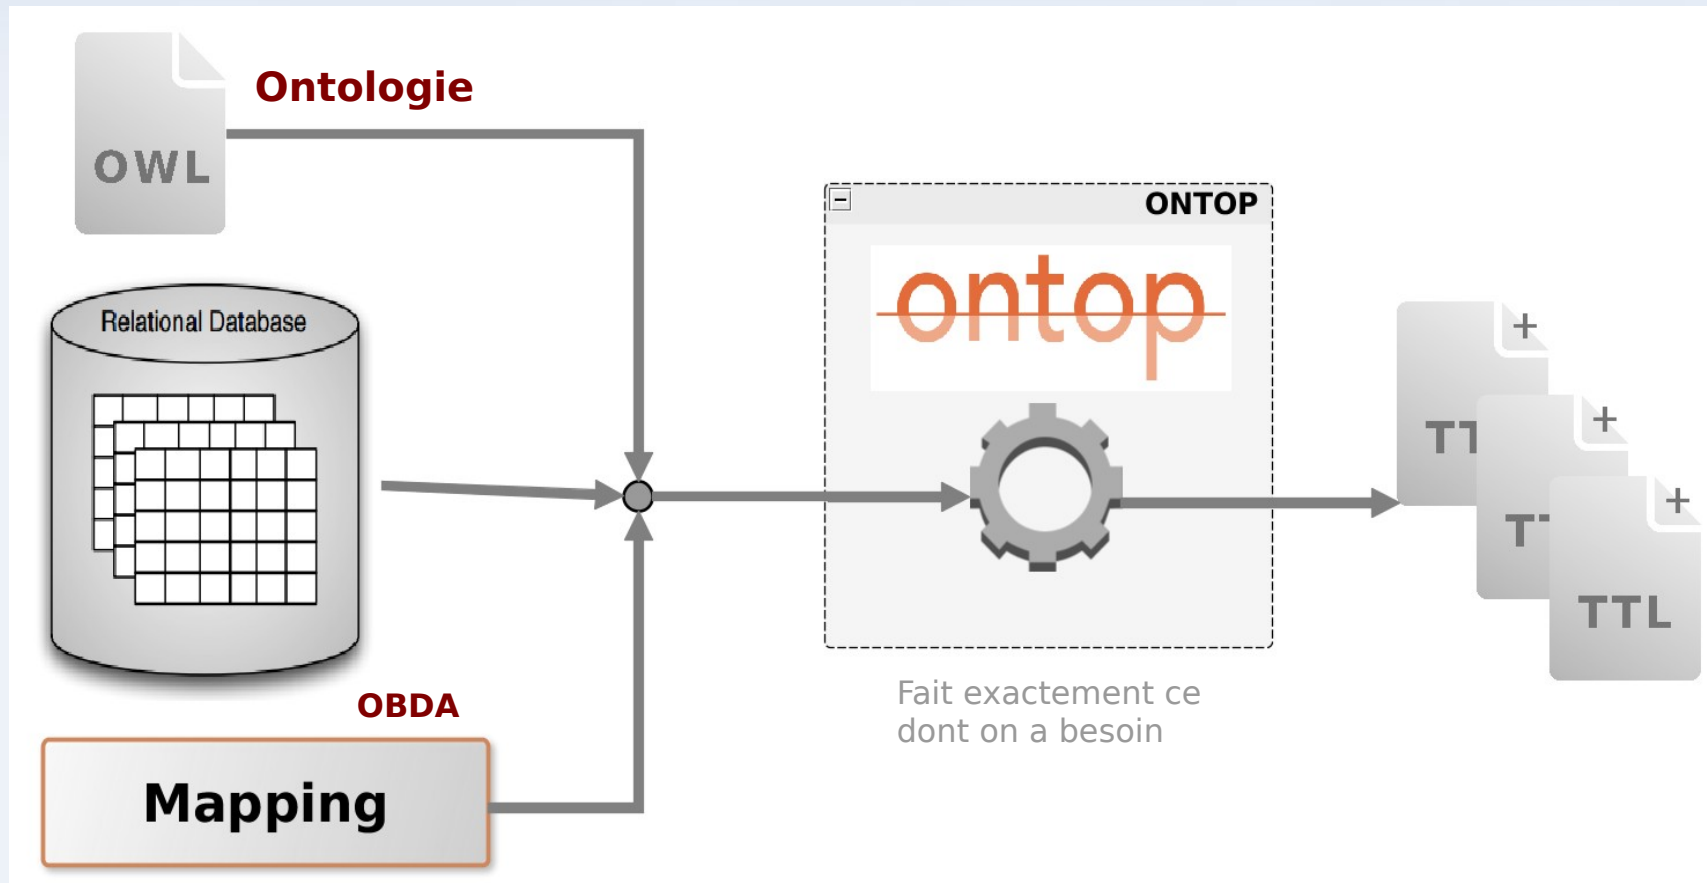
- Mapping Intuitif (se base sur le SQL)

- ~~GUI intergée à Protegé~~- ~~Support « uniquement » SPARQL 1.0~~

Inventaire des outils sémantiques (Phase d'annotation)



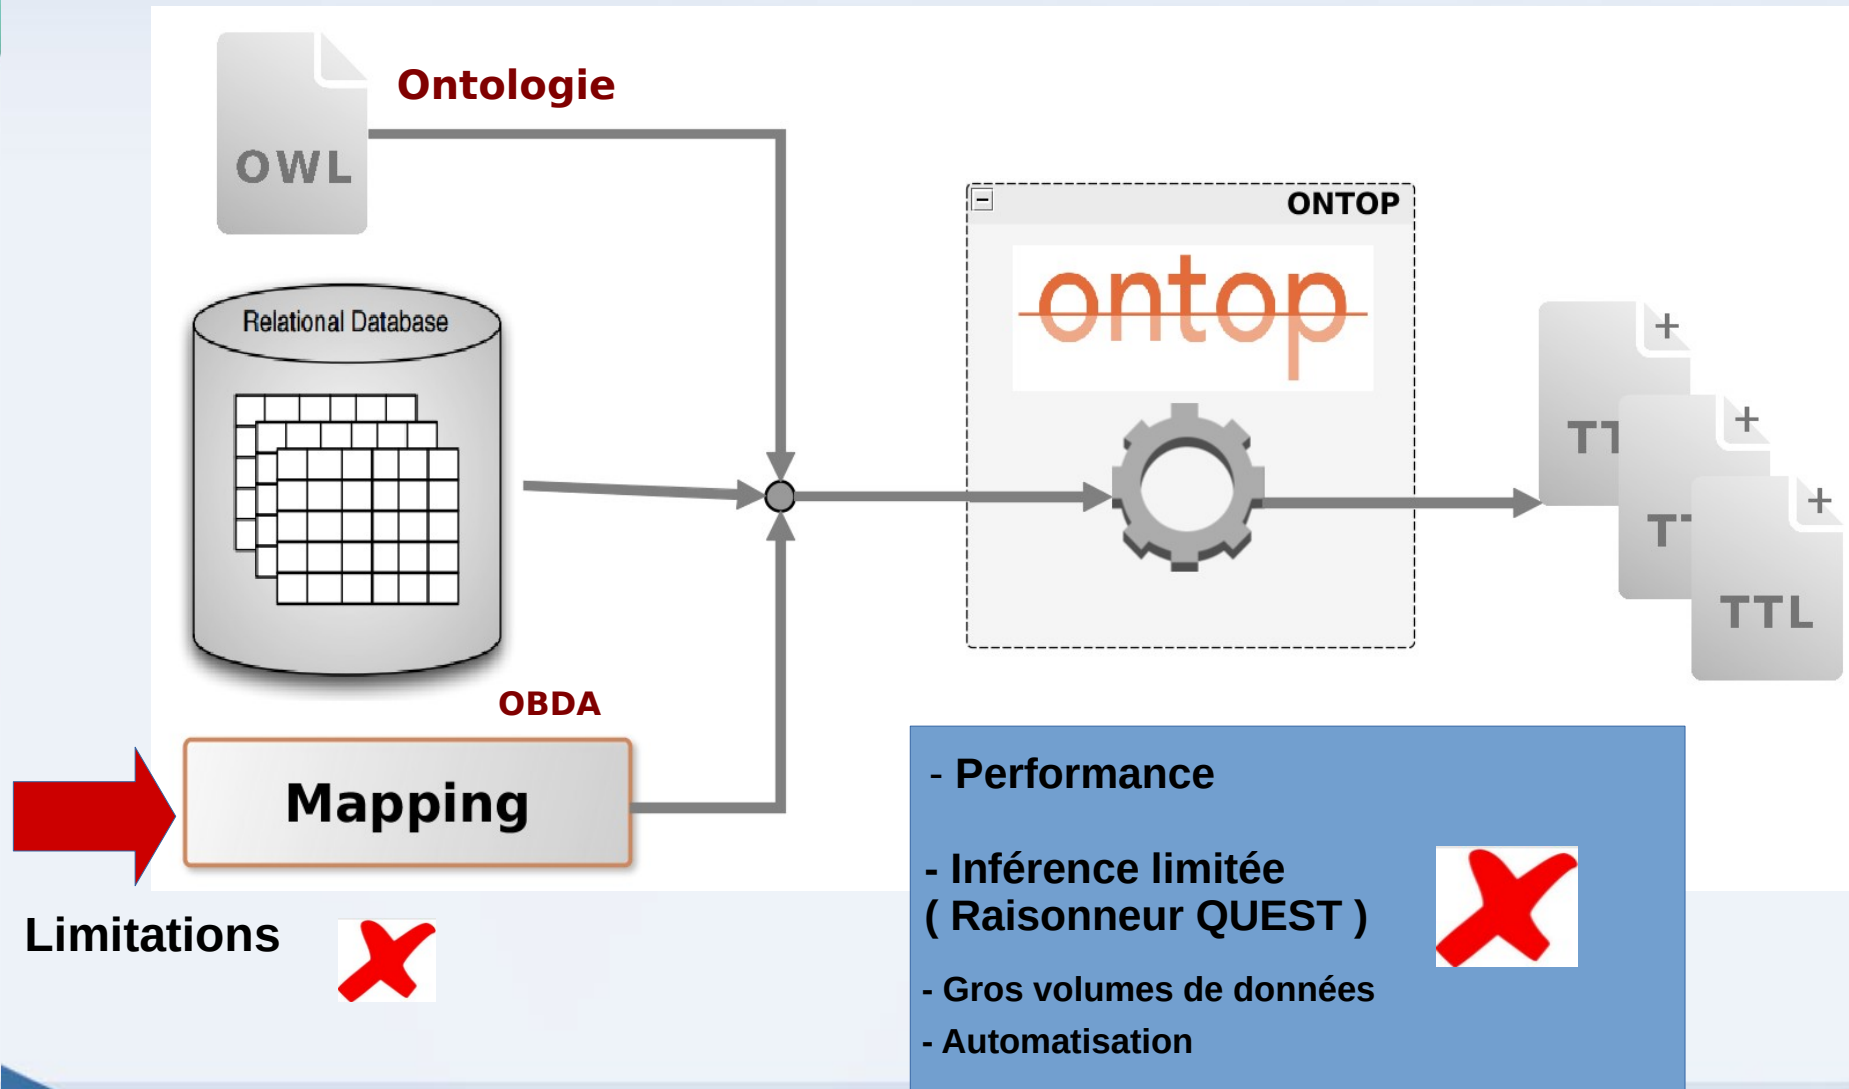
L'outil retenu : **Ontop**




Comment les données
relationnelles sont transformées
en données sémantique...

Limitation...

Inventaire des outils sémantiques (Phase d'annotation)



Inventaire des outils sémantiques (Limitations) (Phase d'annotation)



Contournement des limitations..



Ontop - Protegé

Ontop fourni une interface intergée à Protégé qui facilite la création des mapping.

Protegé : outil open-source pour la création et l'édition des ontologies

3 parties sont distinguées..

The screenshot displays the Ontop-Protégé interface with three main components highlighted:

- Partie DB (1):** The 'Datasource editor' window shows connection parameters for a PostgreSQL database:
 - Connection URL: `jdbc:postgresql://127.0.0.1/ola`
 - Database User: `ryahiaoui`
 - Database Password: `*****`
 - Driver class: `org.postgresql.Driver`
- Partie Target (2):** The 'Edit Mapping' window shows the 'Target (Triples Template)' for the mapping `measurement-ph-water`:
 - Mapping ID: `measurement-ph-water`
 - Target (Triples Template):


```

          :observation
          oboe-core:measurement/ph/water/{vmchimie_id} a oboe-core:Measurement ;
          oboe-core:hasValue {valeur} ; oboe-core:usesStandard :Ph ;
          oboe-core:ofCharacteristic :Ph .
          
```
- Partie Source (3):** The 'Edit Mapping' window also shows the 'Source (SQL Query)':
 - Source (SQL Query):


```

          SELECT
            valeur_mesure_chimie_vmchimie.valeur
          FROM
            valeur_mesure_chimie_vmchimie
          INNER JOIN variable_glacpe_varg
            ON valeur_mesure_chimie_vmchimie.var_id = variable_glacpe_varg.id
          WHERE
            variable_glacpe_varg.affichage = 'pH'
          
```

Additional elements visible in the interface include the 'Class hierarchy: Measurement' on the left, the 'Mapping manager' at the top, and the 'Mapping Assistant - BETA' window at the bottom.

Créer les annotation à la main

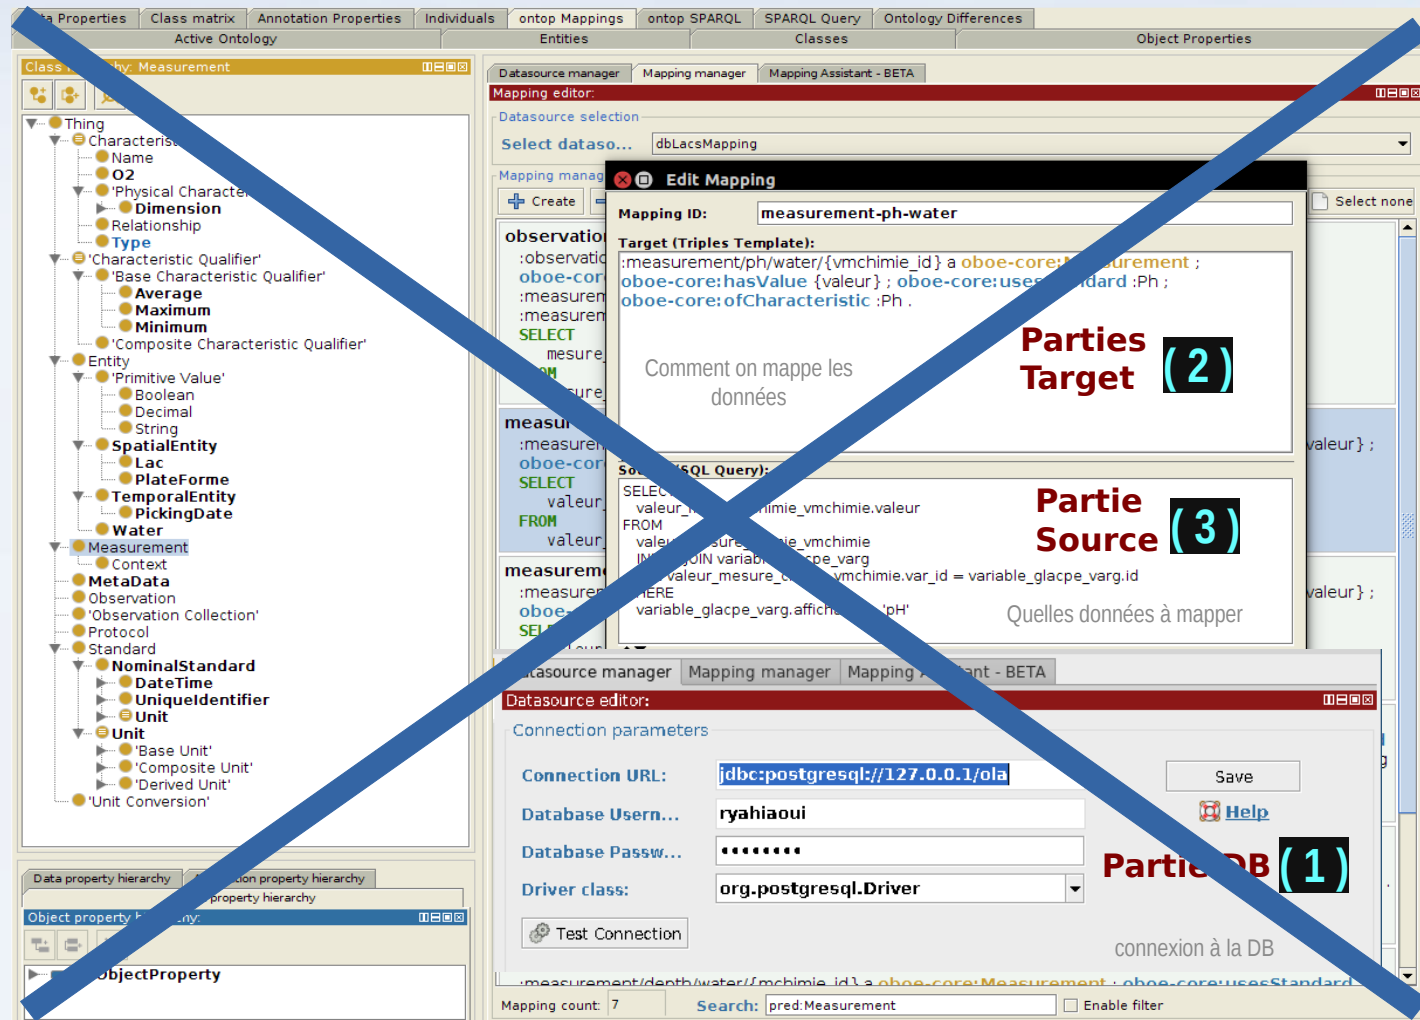


Ontop - Protegé

Ontop fourni une interface intergée à Protégé qui facilite la création des mapping.

Protegé : outil open-source pour la création et l'édition des ontologies

3 parties sont distinguées..



Créer les annotation à la main



En coulisse... Ontop manipule des fichiers OBDA (basé sur le langage R2RML)

(R2RML : recommandation du W3C pour faire du mapping RDB-to-RDF)

```
[PrefixDeclaration]
rdf: http://www.w3.org/1999/02/22-rdf-syntax-ns#
oboe-core: http://ecoinformatics.org/oboe/oboe.1.0/oboe-core.owl#
oboe-temporal: http://ecoinformatics.org/oboe/oboe.1.0/oboe-temporal.owl#
xsd: http://www.w3.org/2001/XMLSchema#
: http://www.anaee.fr/ontology/anaee-france_ontology#
oboe-standard: http://ecoinformatics.org/oboe/oboe.1.0/oboe-standards.owl#
oboe-characteristics: http://ecoinformatics.org/oboe/oboe.1.0/oboe-characteristics.owl#
oboe-spatial: http://ecoinformatics.org/oboe/oboe.1.0/oboe-spatial.owl#
oboe-standards: http://ecoinformatics.org/oboe/oboe.1.0/oboe-standards.owl#
rdfs: http://www.w3.org/2000/01/rdf-schema#
```

```
[SourceDeclaration]
sourceUri dbLacsMapping
connectionUrl jdbc:postgresql://127.0.0.1/ola?sendBufferSize=5000
username ryahiaoui
password yahiaoui
driverClass org.postgresql.Driver
```

```
[MappingDeclaration] @collection []
```

```
mappingId (52) ola characteristic depthRelativeToSurface min
target :ola/characteristic/depthRelativeToSurface/min a :DepthRelativeToSurface
oboe-core:hasQualifier :Minimum
source SELECT id from (values ('1')) s(id) ;
```

Interesting thing ..

The 3 parts that was discussed previously

how can we
automate the
generation of
this kind of the
mapping files

(1) Informations de connexion à la BD

(2)

(3)

Comment on mappe les données

Quelle donnée à mapper

3 Parties importantes

* Partie DB

(1) Informations d'accès à la BD Informations

* Partie Target

(2) Comment sont mappées les données

Règle : Graphes sont composés de nœuds. Chaque nœud non terminal est identifié par un URI

Partie Target = URI + Syntaxe Turtle

* Partie Source

(3) Quelles sont les données concernées par ce mapping

Utilisation de requêtes SQL



Exemple d'une Syntaxe Turtle (**Partie Target**)

```
Measurement(61) a                :Measurement ;
:OfCharacteristic :Latitude
:usesStandard    :DecimalDegree
:hasValue        '10'
```



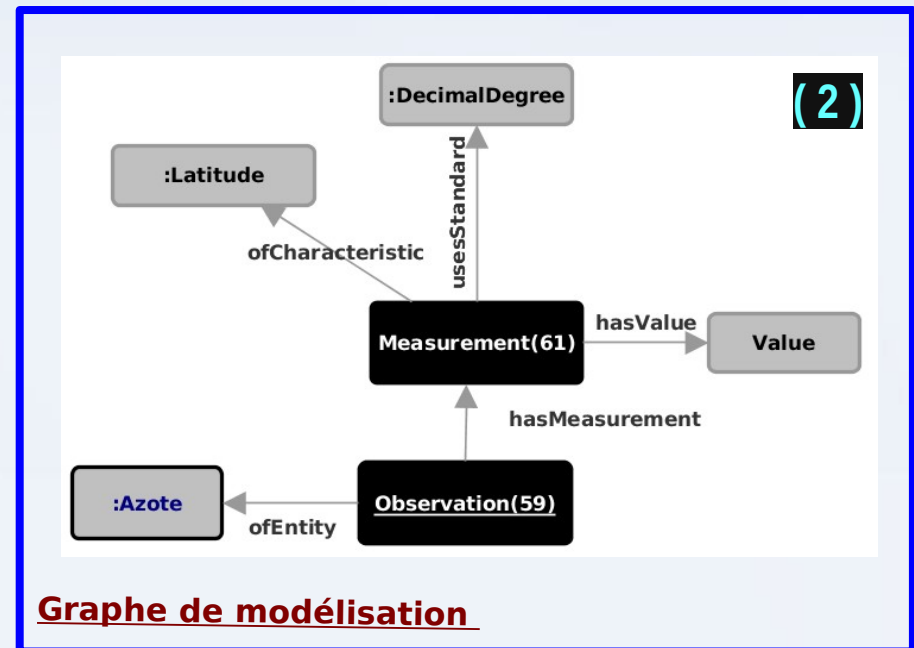
Représentation sous
forme d'un Graphe

⇒ À Partir d'un graphe de modélisation, on peut
générer (assez simplement) la **Partie Target**
(décrite dans les fichiers OBDA)

À condition de fournir un URI pour chaque
nœud non terminal

Sachant que les graphes sont un outil simple (car
facilement manipulable par les scientifiques) et en
même temps puissants pour faire de la modélisation
sémantique..

Partie Target



**Pourquoi ne pas générer les fichiers de
mapping (OBDA) à partir de ces
graphes de modélisation 'sémantique'
(fournis par les scientifiques) ??**



Partie Target

Informations de connexion à la BD (1)

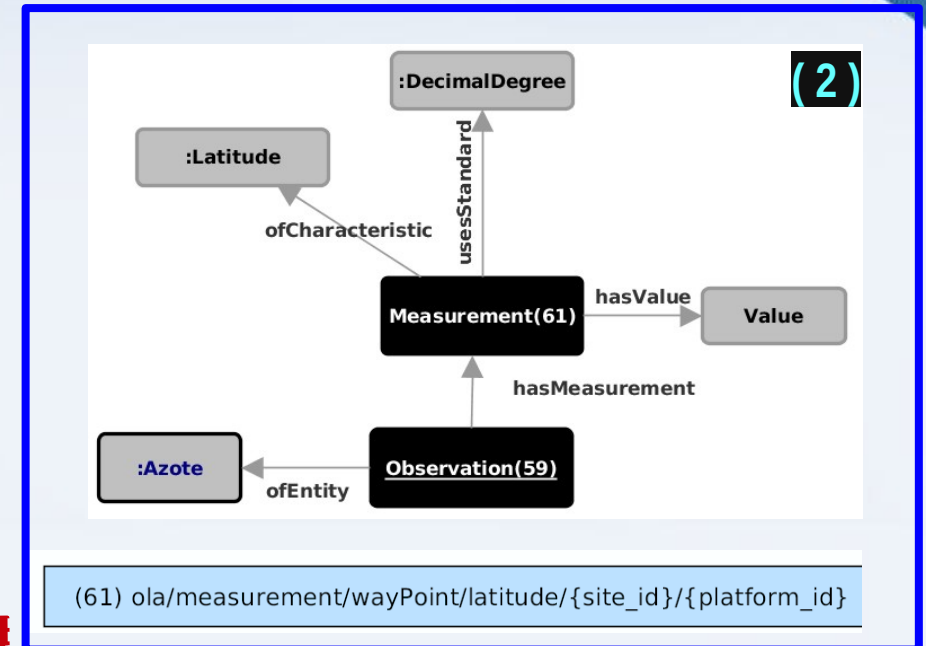
obda-sourceUri : dbLacsMapping

obda-connectionUri : jdbc:postgresql://127.0.0.1/ola?sendBufferSize=5000


obda-username : ryahiaoui

obda-password : yahiaoui

obda-driverClass : org.postgresql.Driver



YedGen : Outil de
génération de
fichiers OBDA à
partir de graphes
de modélisation



Assigner une requête SQL pour chaque nœud non terminal

Query_(61) : SELECT pla.loc_id AS platform_id, site.id AS site_id, pla.latitude AS latitude (3)
FROM
public.site_glacpe_sit site INNER JOIN public.plateforme_pla pla ON site.id = pla.id

Partie Source

C'est ainsi qu'à été résolu le problème de l'automatisation..



Généricité

Par généricité, on entend l'utilisation d'un **même graphe** pour modéliser plusieurs variables (renseignées potentiellement dans un fichier CVS)

Pourquoi ? Parce que ces Variables ont la même structure dans la BD

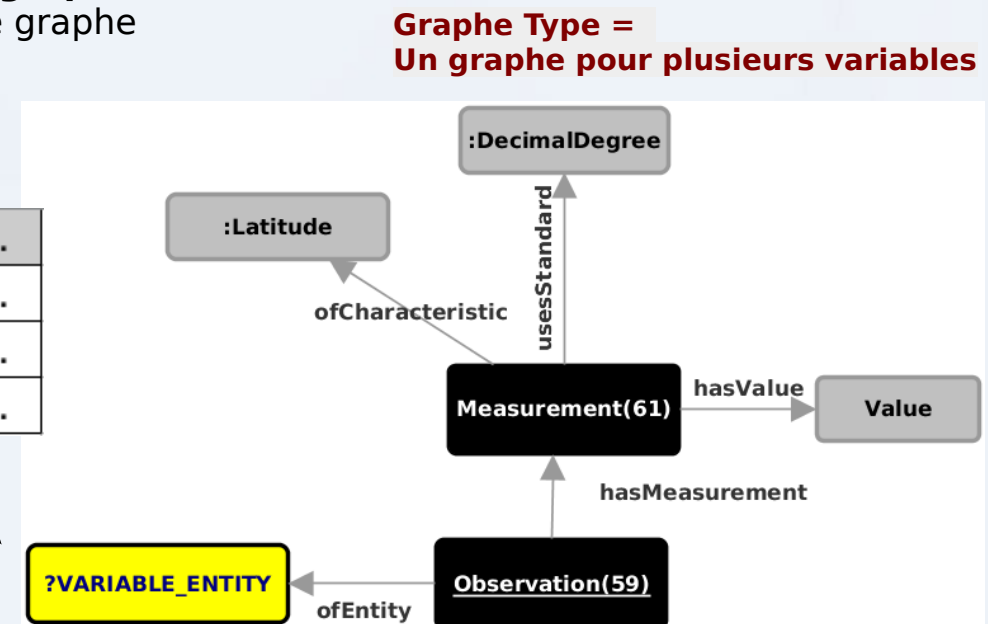
Au lieu d'avoir un graphe par variable, on aura donc un **graphe type** (désigné pour plusieurs variables), et à partir de ce graphe type, générer un fichier de mapping (OBDA) par variable

Cette généricité concerne le fonctionnement de l'outil yedGen

Description d'un fichier CSV de variables sémantiques

	AnaEE Standar	Entity	Context	..
1	cumulative rainfall	cumulative rain		..
2	air carbon dioxide	carbon dioxyde	atmosphere,	..
3	atmospheric air sta	air	atmosphere	..

Appliquer sur la variable **VARIABLE_ENTITY** chaque valeur de la colonne **Entity** du fichier **CSV**. Ce qui nous donne ...

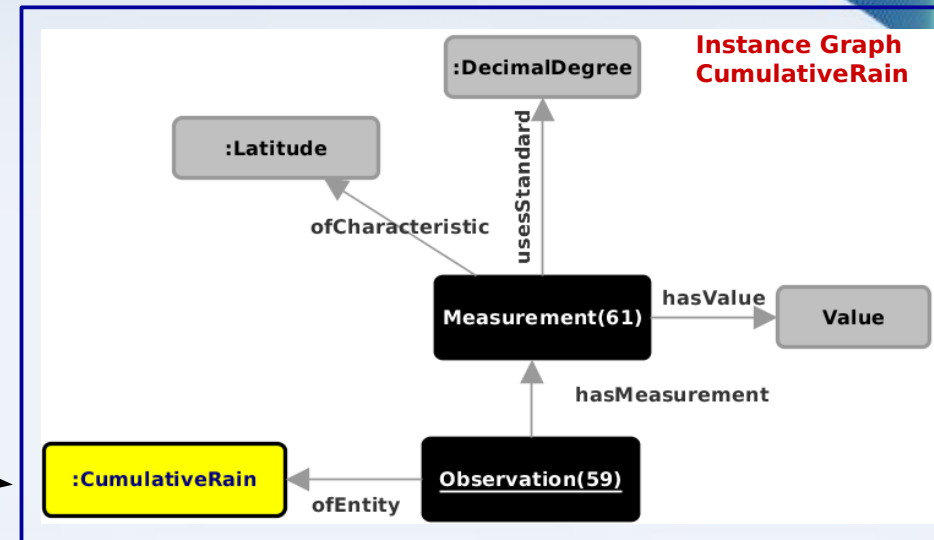




Généricité

Description d'un fichier CSV de variables sémantiques

AnaEE Standar	Entity	Context	..
cumulative rainfall	cumulative rain		..
air carbon dioxide	carbon dioxyde	atmosphere	..
atmospheric air sta	air	atmosphere	..

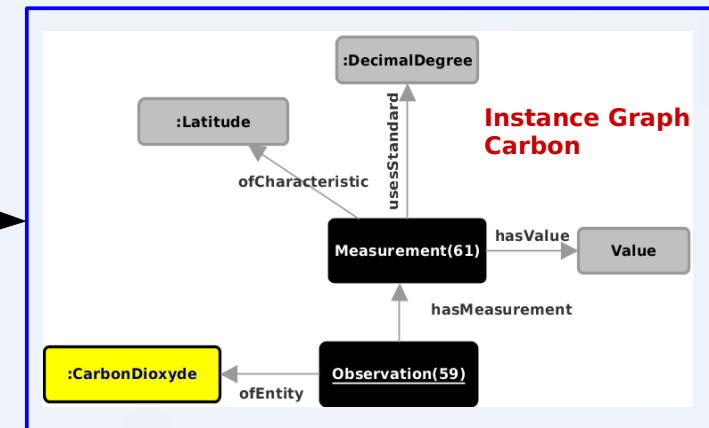




Généricité

Description d'un fichier CSV de variables sémantiques

AnaEE Standar	Entity	Context	..
cumulative rainfall	cumulative rain		..
air carbon dioxide	carbon dioxide	atmosphere	..
atmospheric air sta	air	atmosphere	..

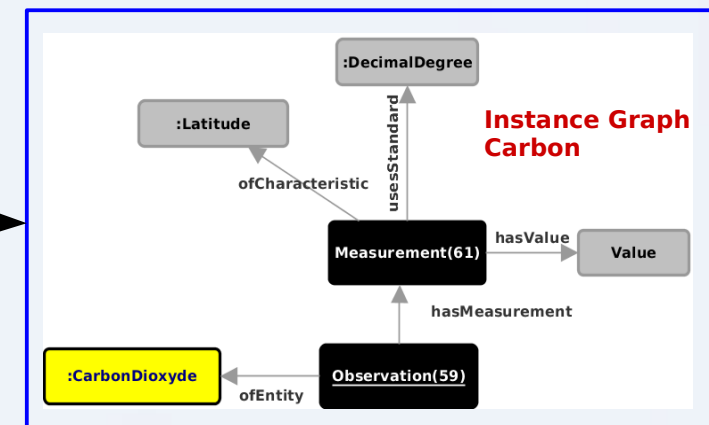
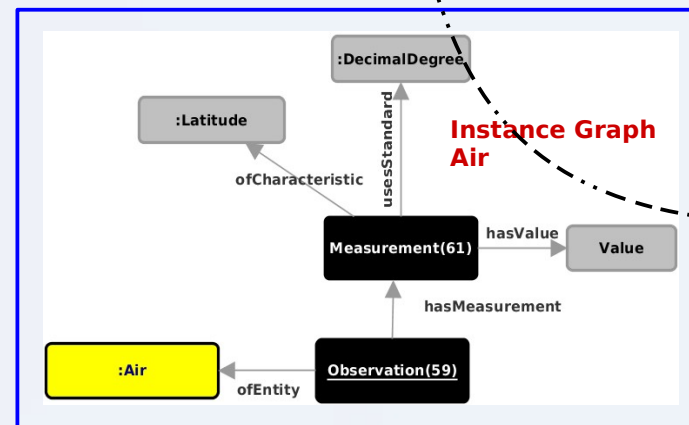
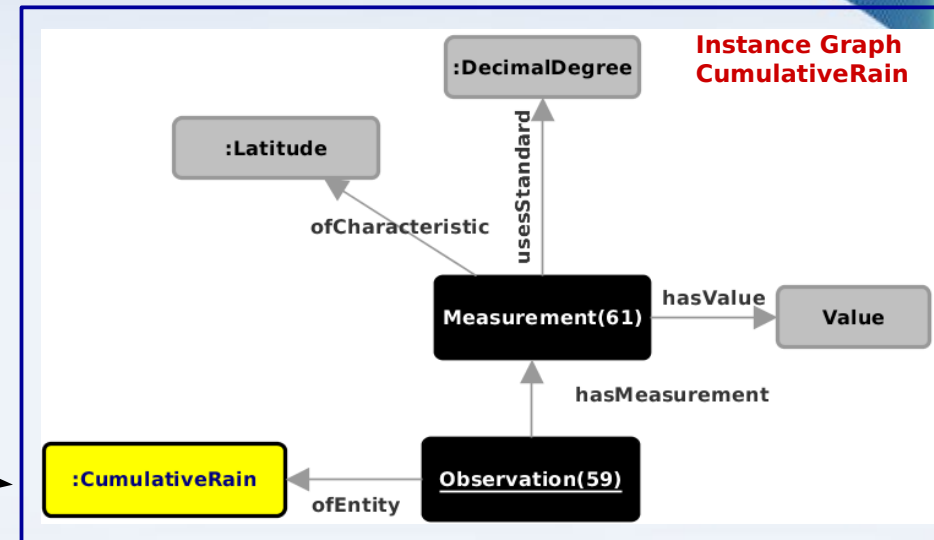




Généricité

Description d'un fichier CSV de variables sémantiques

AnaEE Standar	Entity	Context	..
cumulative rainfall	cumulative rain		..
air carbon dioxide	carbon dioxyde	atmosphere	..
atmospheric air sta	air	atmosphere	..






Généricité


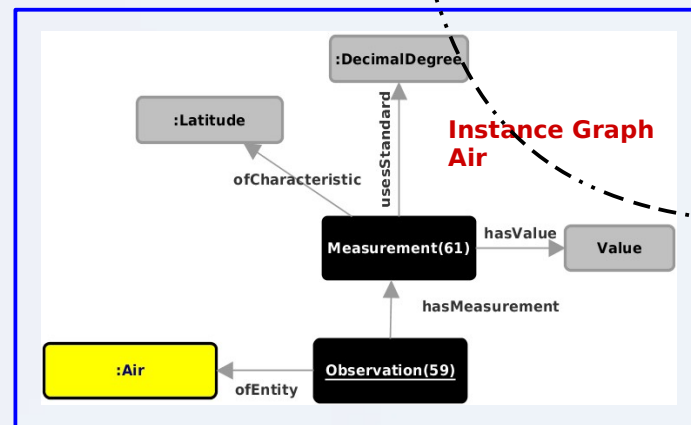

Description d'un fichier CSV de variables sémantiques

AnaEE Standar	Entity	Context	..
cumulative rainfall	cumulative rain		..
air carbon dioxide	carbon dioxide	atmosphere	..
atmospheric air sta	air	atmosphere	..

Le même process est répété pour chaque ligne du CSV..



C'est ainsi qu'à été approché la problématique de la généricité

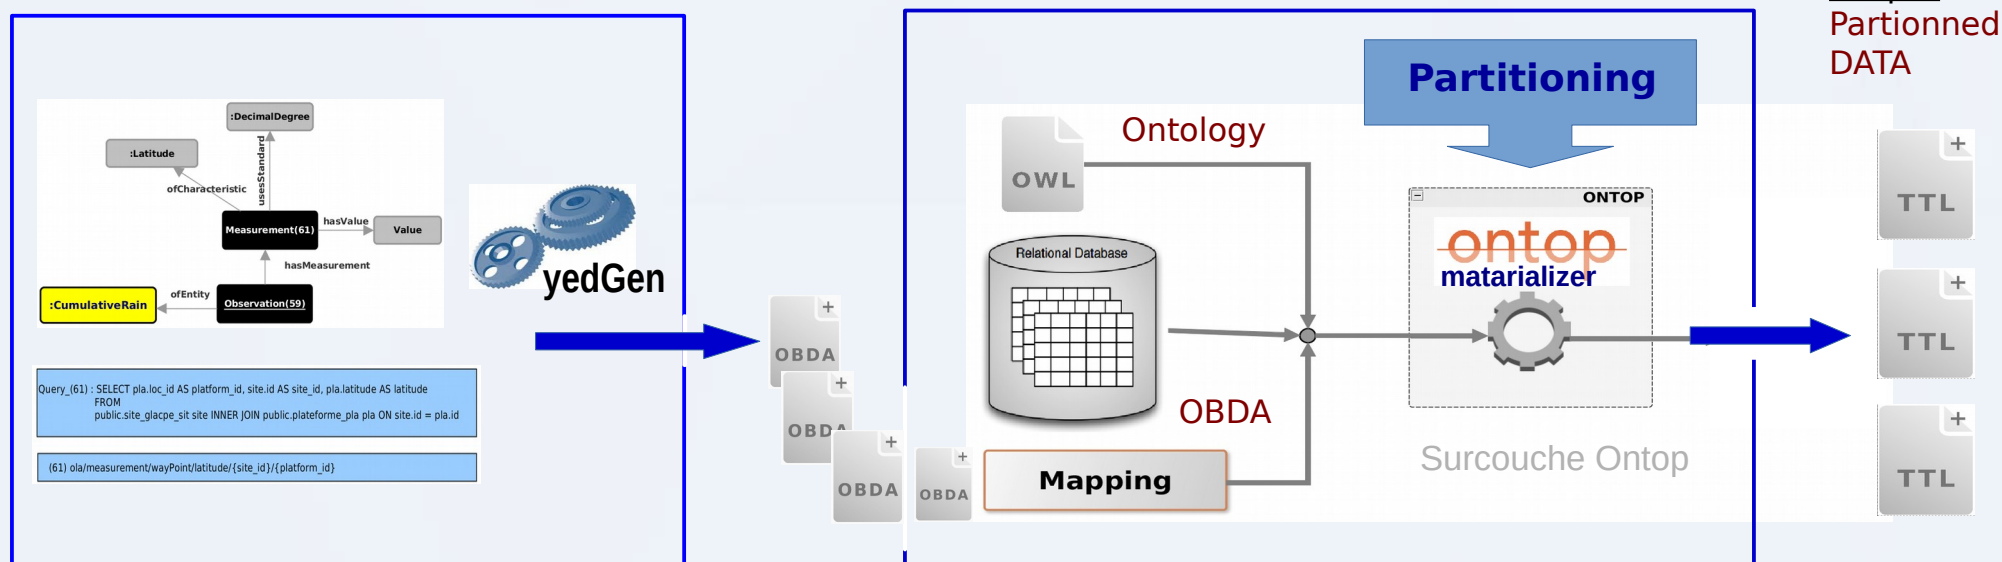




Gros Fichiers / Grosse Bases de données

Il arrive parfois que le volume de données traité par **ONTOP** et **BlazeGraph** dépasse la capacité mémoire de la machine, dans ce cas, on est confronté à des **Outofmemoryerrors**

Solution : **Volume data Partitioning** → Traitement des données par chunk (LIMIT/OFFSET)



→ Traiter un volume « infini » de données



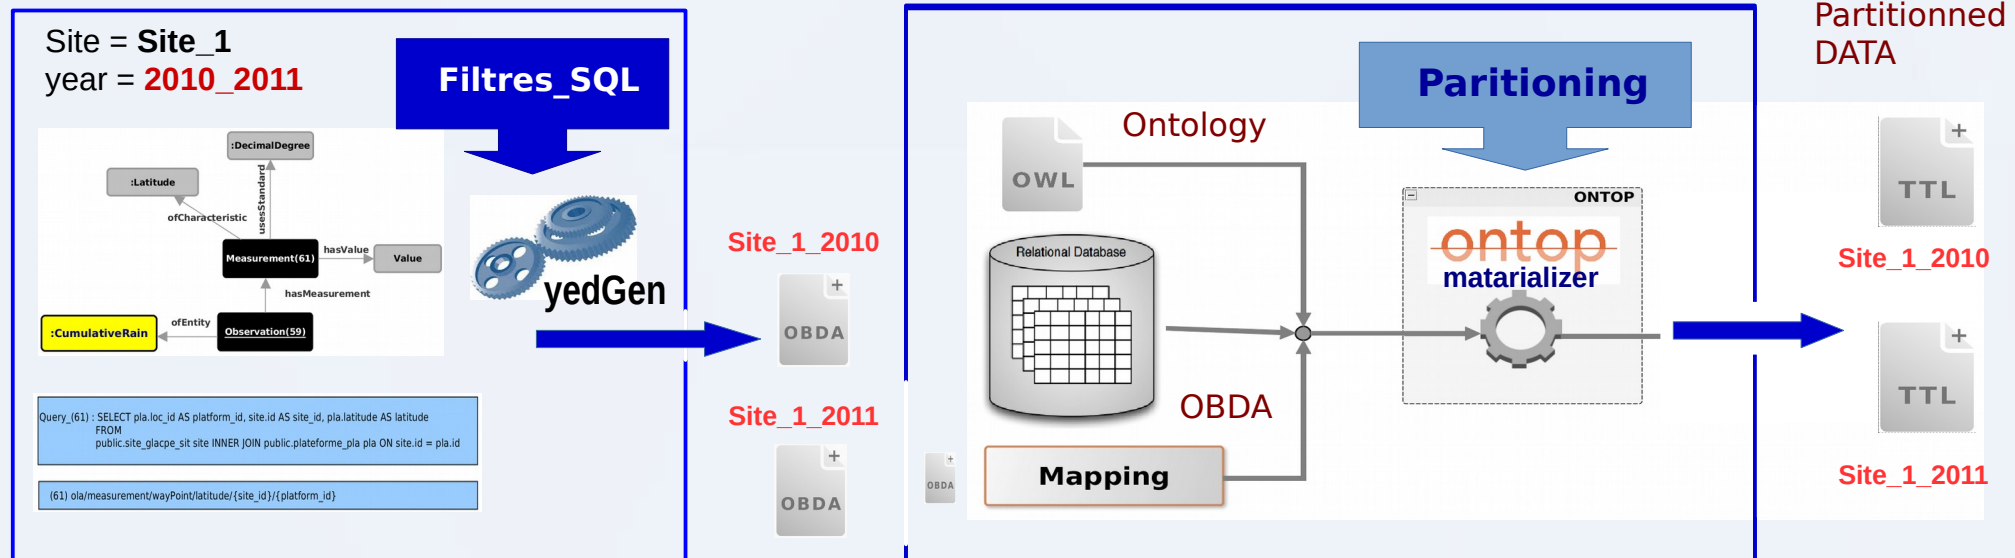
Filtre sur les données

Pour certains use cases, on a besoin de n'extraire que la donnée dont l'utilisateur a besoin

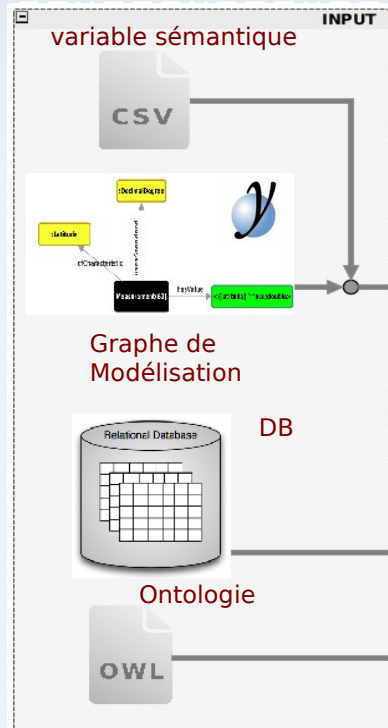
Solution : **Logical data partitioning**

Exemple : Générer des données spécifiques à une **variable** particulière, pour un **site** particulier et un intervalle **d'années** précis

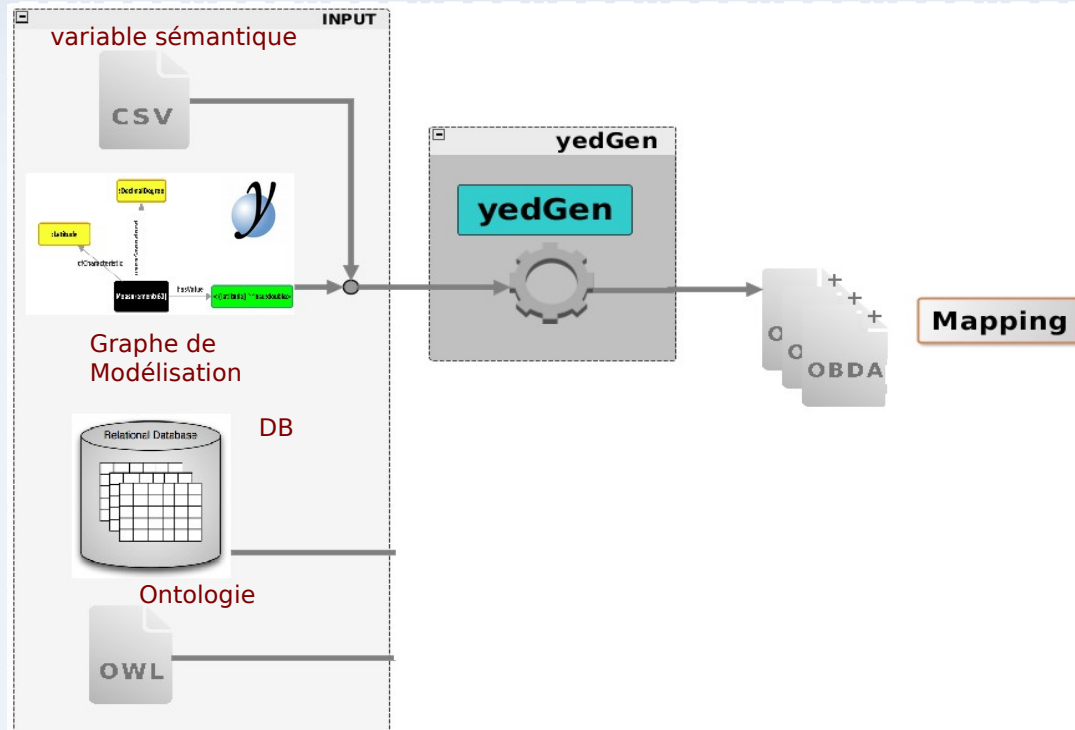
Plus vous filtrez les données, moins vous en avez, plus vous êtes performant



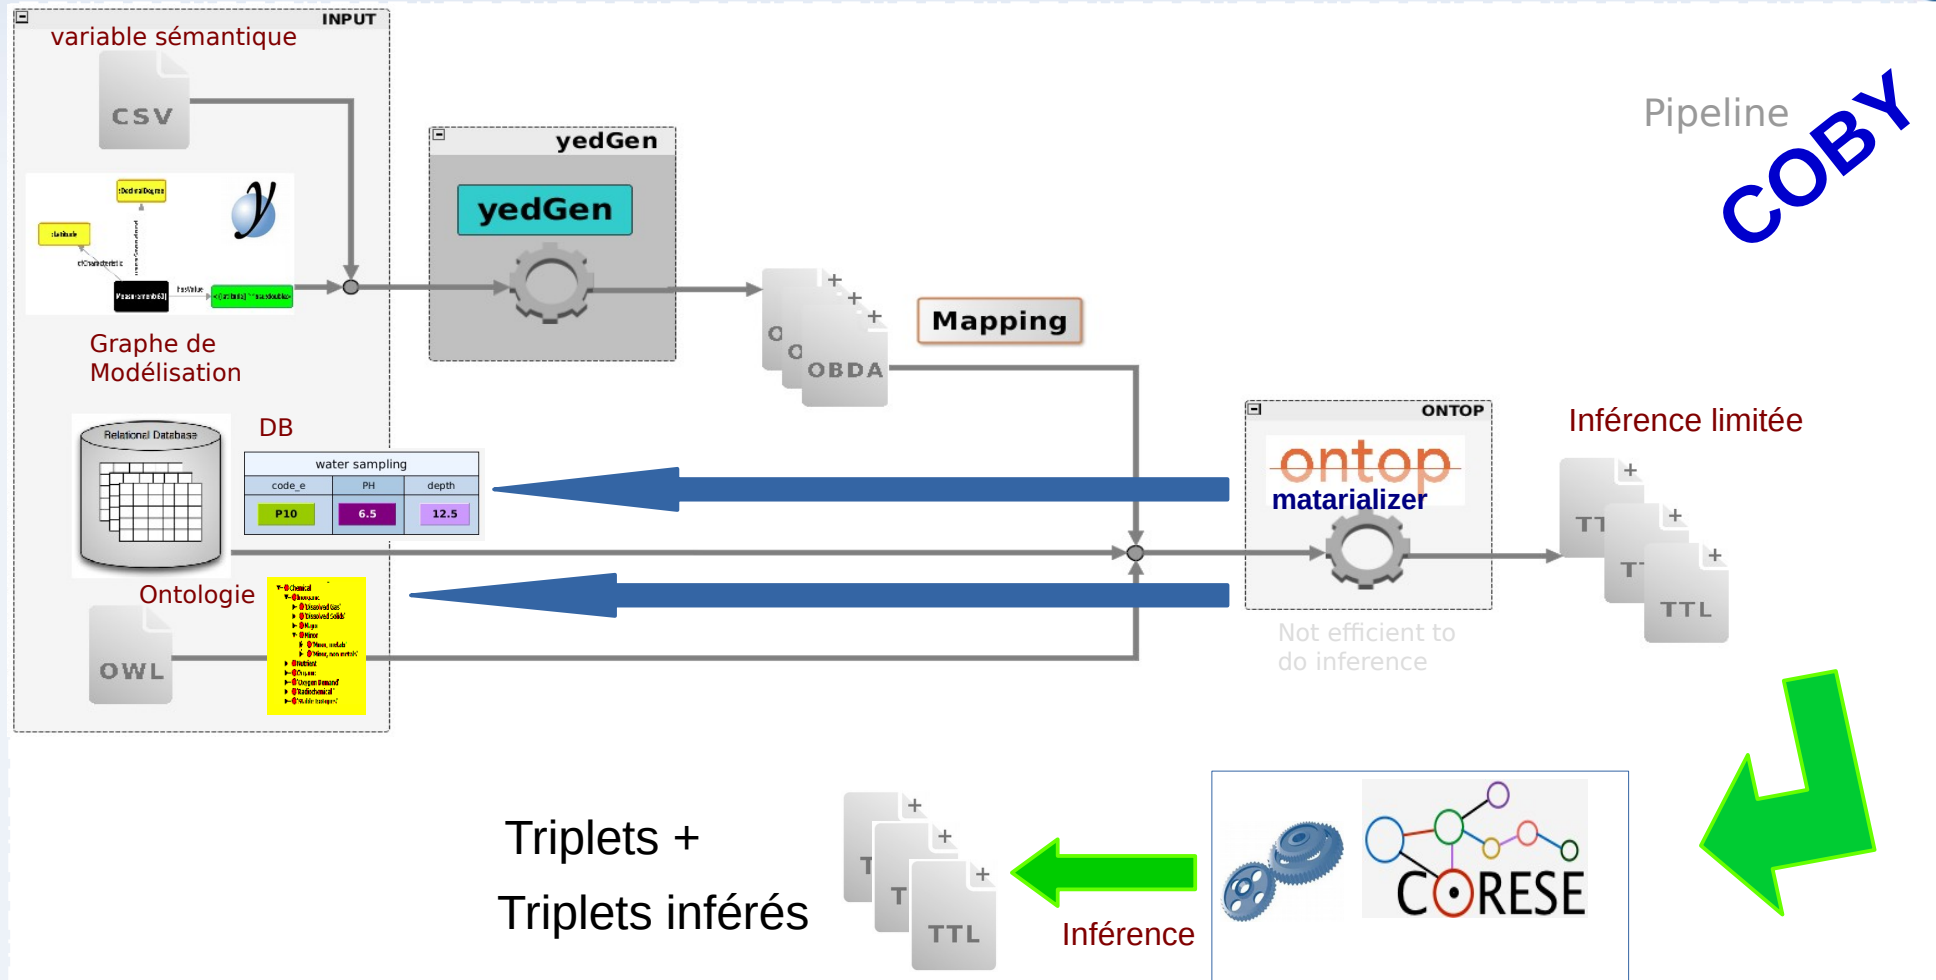
Remarque : Volume data partitioning & Logical data partitioning peuvent être **combinés**



Pipeline



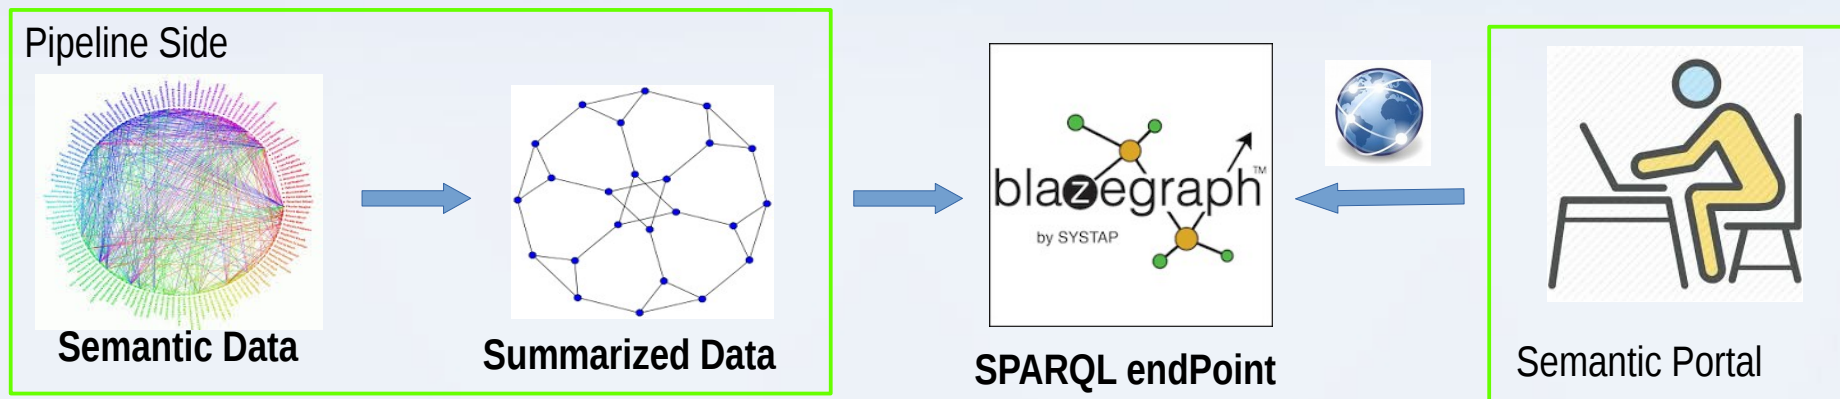
Pipeline



1 – Données de synthèse (sémantiques) pour le portail Anaee-F

Use Case 1


Portal side



Objectif : Production de données de synthèse sémantique par le pipeline d'annotation, et publication de ces dernières sur un Sparql-Endpoint directement accessible par le Portail AnaEE-F

2 - Production de données + métadonnées

Use Case 2



Objectif : Production de données sémantiques filtrées (au format N-Triples), qui seront utilisées pour produire des fichiers au format **netCDF** (jeu de donnée qui descend au grain de la donnée) / Format **GeoDCAT** (sémantique) auquel on applique du XSLT pour le transformer en **ISO-19139**

- **yedGen : Génération instantanée des fichiers de mapping (OBDA) à partir des graphes de modélisation**
⇒ **Passage instantané : Modélisation → Fichiers d'Annotation**
- **Image Docker pré-configurée du pipeline & Déployable en un clique (en fournissant les graphes + CSV)**
- **Généricité ***
- **Métriques :**

(Machine test : 17 / 8 Cores / 5 Go Heap / HDD)

- | | | | |
|--------------------------------------|---|------------------|---------------|
| * Génération (Ontop) | ~ | 700.000 | triplets / mn |
| * Inférence (Moteur Corese) | ~ | 2.600.000 | triplets / mn |
| * Chargement (BlazeGraph) | ~ | 3.000.000 | triplets / mn |

**** À l'échelle des SOERE :**

Modélisation de nouveaux types de données

⇒ Consiste à la création de nouveaux modèles d'annotations pour les variables stockées en base de données en utilisant l'outil **Yed Graph Editor** pour les graphes

**** À l'échelle du Pipeline :**

- Augmenter les performances en introduisant du traitement distribué ⇒
[Technologie Docker**] → Un Fichier OBDA (Mapping) par conteneur Docker)
- Développement d'un PSL (Pipeline Specific Langage) ⇒
Simplification d'écriture des Orchestrateurs (use cases – écrit actuellement en Bash !)
- Autres pistes : **Apache RYA** !

Docker : Technologie de « conteneurisation »

MERCI DE VOTRE
ATTENTION

